

Katedra informatiky
Přírodovědecká fakulta
Univerzita Palackého v Olomouci

BAKALÁŘSKÁ PRÁCE

Grafové databáze – přehled a srovnání



2023

Vedoucí práce:
Mgr. Tomáš Urbanec

Jan Gaja

Studijní program: Informatika,
Specializace: Obecná informatika

Bibliografické údaje

Autor: Jan Gaja
Název práce: Grafové databáze – přehled a srovnání
Typ práce: bakalářská práce
Pracoviště: Katedra informatiky, Přírodovědecká fakulta, Univerzita Palackého v Olomouci
Rok obhajoby: 2023
Studijní program: Informatika, Specializace: Obecná informatika
Vedoucí práce: Mgr. Tomáš Urbanec
Počet stran: 12
Přílohy: 1 CD/DVD
Jazyk práce: český

Bibliographic info

Author: Jan Gaja
Title: Graph databases – overview and comparison
Thesis type: bachelor thesis
Department: Department of Computer Science, Faculty of Science, Palacký University Olomouc
Year of defense: 2023
Study program: Computer Science, Specialization: General Computer Science
Supervisor: Mgr. Tomáš Urbanec
Page count: 12
Supplements: 1 CD/DVD
Thesis language: Czech

Anotace

Práce má dva cíle: 1. nastudovat principy ukládání a práce s daty v grafových databázích a získané poznatky sepsat do textu, který čtenáři poskytne dobrou představu o fungování, výhodách a nevýhodách tohoto přístupu k datům. 2. vybrat několik implementací grafových databází, nachystat ukázky jejich použití a pokusit se navrhnout experimenty ukazující silné a slabé stránky zvolených implementací.

Synopsis

Thesis has two goals: 1. study the principles of storing and working with data in graph databases and and write down the knowledge gained in a text that will give the reader a good idea of how it works, advantages and disadvantages of this approach to data. 2. select several implementations of graph databases, prepare examples of their use and try to devise experiments showing the strengths and weaknesses of the selected implementation.

Klíčová slova: grafové databáze; implementace grafových databází

Keywords: graph databases; implementation of graph databases

Děkuji, děkuji, děkuji.

Místopřísežně prohlašuji, že jsem celou práci včetně příloh vypracoval/a samostatně a za použití pouze zdrojů citovaných v textu práce a uvedených v seznamu literatury.

datum odevzdání práce

podpis autora

Obsah

1	Grafové databáze	7
1.1	Základní pojmy z teorie grafů	7
1.2	Výhody grafových databází	8
1.3	Nevýhody grafových databází	8
1.4	Modelování grafových dat	8
2	Implementace grafových databází	9
2.1	Neo4j	9
2.2	OrientDB	9
2.3	Dotazovací jazyky v grafových databázích	9
2.3.1	Gremlin	9
2.3.2	Cypher	9
2.3.3	GQL - Graph Query Language	9
	Závěr	10
	Conclusions	11
	Seznam zkratk	12

Seznam tabulek

1 Grafové databáze

Grafové databáze, stejně jako jiné databáze (například relační, NoSQL) představují systém pro uchovávání a zpracovávání dat. Jsou, jak již název napovídá, postaveny na jednom z oborů diskrétní matematiky jménem teorie grafů, podobně jako jsou relační databáze postaveny na pojmu relace. Díky této struktuře mají skvělé vlastnosti pro aplikace, které ve větší míře pracují se vztahy mezi jednotlivými entitami.

1.1 Základní pojmy z teorie grafů

V této části jsou uvedeny základní definice z teorie grafů používané v textu.

Definice 1 (Graf)

Graf je uspořádaná dvojice $\langle V, E \rangle$, kde V označuje množinu vrcholů a E označuje množinu hran. Každá hrana je určena dvěma vrcholy z V , které spojuje.

Grafy se dělí na orientované a neorientované. Hrana v neorientovaném grafu mezi vrcholy u a v se nazývá neorientovaná a zapisuje se pomocí množiny obsahující dvojici vrcholů, tedy u, v . V případě orientovaného grafu se hrana nazývá orientovaná a pro zápis se používá uspořádaná dvojice. Orientovaná hrana (u, v) začíná ve vrcholu u a končí ve vrcholu v . Grafy se nejčastěji znázorňují pomocí kroužků, které představují vrcholy, a úseček mezi nimi, sloužící pro reprezentaci hran. Pokud se jedná o orientovaný graf místo úseček používáme šipky. Pro hrany používáme označení násobné, pokud existuje mezi dvěma vrcholy hran více. O hraně začínající i končící ve stejném vrcholu mluvíme jako o smyčce.

Definice 2 (Podgraf)

Podgraf grafu $G = \langle V, E \rangle$ je graf $H = \langle V_1, E_1 \rangle$, kde $V_1 \subseteq V$ a $E_1 \subseteq E$, tak že každá hrana z E_1 má oba vrcholy ve V_1 .

Definice 3 (Stupeň vrcholu)

Stupněm vrcholu u v grafu $G = \langle V, E \rangle$ se rozumí počet hran dotýkajících se u . Stupeň vrcholu u lze v orientovaném grafu dále rozdělit podle hran vcházejících a vycházejících na vstupní a výstupní.

Definice 4 (Cesta)

Cesta je sekvence vrcholů a hran, kde se vrcholy ani hrany neopakují. Cesta délky n má $n + 1$ vrcholů.

Definice 5 (Kružnice)

Kružnice je cesta, kde počáteční a koncový vrchol je stejný.

Definice 6 (Vzdálenost)

Vzdálenost z vrcholu u do vrcholu v lze definovat jako délku nejkratší cesty

z u do v.

Definice 7 (Strom)

Strom je souvislý graf neobsahující kružnice.

1.2 Výhody grafových databází

Velkou výhodou těchto systémů je, že uchovávají jak samotné entity, tak všechny vztahy mezi entitami. Tedy při dotazování nedochází k výpočtu těchto vztahů, jak tomu je například u relačních databází pomocí klauzule JOIN. Tato přednost zrychluje zpracování dotazů. Grafové databáze jsou proto vhodné pro data, které jsou hustě propojená. Relace a vztahy mezi entitami jsou zde stejně důležité, ne-li důležitější, než samotné entity. Nejznámějším příkladem takových dat jsou data ze sociálních sítí. Sociální sítě často disponují funkcí nabízení nových přátel, se kterými by se uživatel mohl chtít spojit. Jedním ze způsobů je navrhování přátel, kteří již jsou přáteli přátel uživatele. V relačních databázích by takové dotazy obsahovaly řadu JOINů a nebyly by efektivní. Grafové databáze tento problém řeší efektivněji pomocí průchodu grafem. Další příklad, kde je vhodné použít "grafový" přístup jsou například mapy, systémy doporučující zboží, banky. Mezi další výhody patří ...

1.3 Nevýhody grafových databází

Nevýhody grafových databází se projeví při práci s tabulárním typem dat. Například, když bychom data agregovali, chtěli zjistit počet uzlů, sumaci dat. Takové typy dotazů jsou často v grafových databázích neefektivní v porovnání s relačními...

1.4 Modelování grafových dat

Modelování dat je proces, který překládá entity reálného světa a vztahy mezi nimi do jejich softwarové reprezentace. Uživatel popisuje doménu jako graf skládající se z vrcholů a hran pomocí vlastností a popisků. Každý výsledný model je unikátní. U každého záleží na případech použití a typech dotazů, které budou na databázi kladeny. Dodržení základních principů modelování dat je důležité pro výslednou efektivitu. Když je graf přizpůsoben dotazům, dokáže velmi rychle nalézt potřebnou odpověď. Naopak špatně zvolený model grafu může ve výsledku aplikaci ublížit a být překážkou. Proto správnému modelu je dobré věnovat dostatečné množství času a dodržovat obecná pravidla.

Postup modelování se dá rozdělit do čtyř fází:

1. Definice problému
2. Konceptuální datový model
3. Logický datový model

4. Testování modelu

Nechť je potřeba vytvořit aplikaci pro letecké aerolinky. Aplikace by vypisovala lety z jednotlivých letišť a umožnila by i další funkcionality jakou je plánování letu, indikování zpoždění. Postup modelování dat je ukázán na tomto problému.

1.4.1 Definice problému

1.4.2 Konceptuální datový model

1.4.3 Logický datový model

1.4.4 Testování modelu

2 Implementace grafových databází

Existuje spousta implementací grafových databází. Nejznámějšími jsou Neo4j, OrientDB, MemoGraph, TigerGraph, InfiniteGraph...

2.1 Neo4j

Jedná se o nejrozšířenější open-source grafovou databázi. Implementována je v Javě. Nabízí vysoký výkon při práci s grafy. Používá Cypher jako dotazovací jazyk.

2.2 OrientDB

OrientDB je open-source NoSQL databázový systém implementovaný v Javě. Je to multi-model databáze - podporuje grafový, dokumentový, hodnota/klíč a objektový model...

2.3 Dotazovací jazyky v grafových databázích

2.3.1 Gremlin

2.3.2 Cypher

2.3.3 GQL - Graph Query Language

Závěr

Závěr práce v „českém“ jazyce.

Conclusions

Thesis conclusions in “English”.

