

Katedra informatiky
Přírodovědecká fakulta
Univerzita Palackého v Olomouci

BAKALÁŘSKÁ PRÁCE

Grafové databáze – přehled a srovnání



2024

Vedoucí práce:
Mgr. Tomáš Urbanec

Jan Gaja

Studijní program: Informatika,
Specializace: Obecná informatika

Bibliografické údaje

Autor: Jan Gaja
Název práce: Grafové databáze – přehled a srovnání
Typ práce: bakalářská práce
Pracoviště: Katedra informatiky, Přírodovědecká fakulta, Univerzita Palackého v Olomouci
Rok obhajoby: 2024
Studijní program: Informatika, Specializace: Obecná informatika
Vedoucí práce: Mgr. Tomáš Urbanec
Počet stran: 36
Přílohy: 1 CD/DVD
Jazyk práce: český

Bibliographic info

Author: Jan Gaja
Title: Graph databases – overview and comparison
Thesis type: bachelor thesis
Department: Department of Computer Science, Faculty of Science, Palacký University Olomouc
Year of defense: 2024
Study program: Computer Science, Specialization: General Computer Science
Supervisor: Mgr. Tomáš Urbanec
Page count: 36
Supplements: 1 CD/DVD
Thesis language: Czech

Anotace

Práce má dva cíle: 1. nastudovat principy ukládání a práce s daty v grafových databázích a získané poznatky sepsat do textu, který čtenáři poskytne dobrou představu o fungování, výhodách a nevýhodách tohoto přístupu k datům. 2. vybrat několik implementací grafových databází, nachystat ukázky jejich použití a pokusit se navrhnout experimenty ukazující silné a slabé stránky zvolených implementací.

Synopsis

Thesis has two goals: 1. study the principles of storing and working with data in graph databases and and write down the knowledge gained in a text that will give the reader a good idea of how it works, advantages and disadvantages of this approach to data. 2. select several implementations of graph databases, prepare examples of their use and try to devise experiments showing the strengths and weaknesses of the selected implementation.

Klíčová slova: grafové databáze; implementace grafových databází

Keywords: graph databases; implementation of graph databases

Děkuji, děkuji, děkuji.

Místopřísežně prohlašuji, že jsem celou práci včetně příloh vypracoval/a samostatně a za použití pouze zdrojů citovaných v textu práce a uvedených v seznamu literatury.

datum odevzdání práce

podpis autora

Obsah

1	Základní pojmy z teorie grafů	8
2	Modelování grafových dat	11
2.1	Definice problému	14
2.1.1	Co od naší aplikace uživatel očekává?	14
2.1.2	Jaké typy informací naše aplikace potřebuje uchovávat, aby měla danou funkcionalitu?	14
2.1.3	Jak spolu tyto pojmy vzájemně souvisí v rámci aplikace?	15
2.1.4	Na jaké otázky potřebují uživatelé najít odpověď?	15
2.2	Konceptuální datový model	15
2.2.1	Entity	16
2.2.2	Vztahy	16
2.3	Logický datový model	17
2.4	Testování modelu	21
3	Hledání cest mezi 2 vrcholy	21
3.1	Procházení grafu	21
3.1.1	Cesta v neohodnoceném grafu	23
3.1.2	Cesta v ohodnoceném grafu	24
4	Algoritmy	26
4.1	Algoritmy pro hledání cesty v grafu	26
4.1.1	Dijkstra	27
4.1.2	A*	27
4.1.3	Minimální kostra grafu	27
4.1.4	Random walk	28
4.2	Algoritmy pro míru centrality	29
4.2.1	Degree Centrality	30
4.2.2	Closeness Centrality	30
4.2.3	Betweenness Centrality	30
4.2.4	PageRank	31
4.2.5	Použití algoritmů pro míru centrality	31
4.3	Detekce komunit	31
4.3.1	Počítání trojúhelníků	32
4.3.2	Hledání komponent	33
5	Implementace grafových databází	33
5.1	Neo4j	33
5.2	OrientDB	33
5.3	Dotazovací jazyky v grafových databázích	33
5.3.1	Gremlin	33
5.3.2	Cypher	33
5.3.3	GQL - Graph Query Language	33

Závěr	34
Conclusions	35
Seznam zkratk	36

Seznam tabulek

1	Tabulka obsahující soubory vygenerovaných dat pro aplikaci pro cestovní nadšence.	13
2	Tabulka obsahující soubory pro ukázkou hledání cest.	21
3	Výsledná tabulka pro dotaz 1	24
4	Výsledek algoritmu Random walk s parametrem inOutFactor nastaveným na hodnotu 2 zvolaným na stanici s vlastností stationId menší než 10.	29
5	Výsledek algoritmu Random walk s parametrem inOutFactor nastaveným na hodnotu 0.2 zvolaným na stanici s vlastností stationId menší než 10.	29
6	Algoritmy pro měření centrality aplikované na jednotlivé vrcholy z grafu 10	31
7	Počet trojúhelníků a shlukovací koeficient jednotlivých vrcholů z grafu 10	33

Úvod

Grafové databáze, stejně jako jiné databáze (například relační, NoSQL) představují systém pro uchovávání a zpracovávání dat. Jsou, jak již název napovídá, postaveny na jednom z oborů diskrétní matematiky jménem teorie grafů, podobně jako jsou relační databáze postaveny na pojmu relace. Pracují tedy s daty v podobě grafu. Díky této struktuře mají skvělé vlastnosti pro aplikace, které ve větší míře pracují se vztahy mezi jednotlivými entitami.

1 Základní pojmy z teorie grafů

V této části jsou uvedeny základní definice z teorie grafů používané v textu.

Definice 1 (Graf)

Graf G je uspořádaná dvojice $\langle V, E \rangle$, kde V označuje neprázdnou množinu vrcholů a E označuje množinu hran. Každá hrana je určena dvěma vrcholy z V , které spojuje.

V grafu $G = \langle V, E \rangle$ se V nazývá *množina vrcholů* grafu G a označuje se $V(G)$. Podobně E se nazývá *množina hran* grafu G a označuje se $E(G)$.

POZNÁMKA 2 (VRCHOL)

V teorii grafů se pojem vrchol někdy zaměňuje s pojmem uzel. V této práci však budeme používat pojem vrchol.

POZNÁMKA 3 (NEKONEČNÉ GRAFY)

Grafy mohou mít nekonečnou množinu vrcholů. Tyto grafy se nazývají nekonečné. Nekonečné grafy však obecně nelze uchovávat v počítači. V této práci tedy budeme pod pojmem graf myslet graf s konečnou množinou vrcholů.

Grafy se dělí na *orientované* a *neorientované*. Hrana v neorientovaném grafu spojující vrcholy u a v se nazývá *neorientovaná* a zapisuje se pomocí množiny obsahující dvojici vrcholů, tedy $\{u, v\}$. Hrana v orientovaném grafu začínající ve vrcholu u a končící ve vrcholu v se nazývá *orientovaná* a pro zápis se používá uspořádaná dvojice, tedy $\langle u, v \rangle$. O hraně začínající i končící ve stejném vrcholu mluvíme jako o *smyčce*.

Grafy se nejčastěji znázorňují pomocí kroužků, které představují vrcholy, a úseček mezi nimi, sloužící pro reprezentaci hran. Pokud se jedná o orientovaný graf místo úseček používáme šipky. Pro hrany používáme označení *násobné*, pokud existuje mezi dvěma vrcholy hran více.

Orientované i neorientované grafy též mohou mít dodatečnou informaci ve formě *ohodnocení hran*. Obecně ji můžeme definovat jako funkci $w : E \rightarrow \mathbb{R}$. *Ohodnoceným grafem* pak nazveme trojici $G = (V, E, w)$. Hodnotu $w(e)$ pro

hranu $e \in E$ ohodnoceného grafu $G = (V, E, w)$ nazýváme *váha* nebo *ohodnocení hrany* e . Obdobně lze definovat ohodnocení vrcholů jako funkci $w : V \rightarrow \mathbb{R}$.

POZNÁMKA 4 (OHODNOCENÝ GRAF)

Ohodnoceným grafem v textu budeme vždy myslet graf $G = (V, E, w)$, kde přiřazení w je ohodnocení hran.

Definice 5 (Symetrizace orientovaného grafu)

Symetrizace orientovaného grafu $G = \langle V, E \rangle$ je neorientovaný graf $G' = \langle V, E' \rangle$, pokud pro každou hranu $\{u, v\} \in E'$ platí, že $\langle u, v \rangle \in E$, nebo $\langle v, u \rangle \in E$.

Symetrizaci grafu lze popsat jako proces, ve kterém zapomeneme orientaci hran, odstraníme smyčky a vícenásobné hrany nahradíme jednoduchými a vznikne nám tak neorientovaný graf.

Definice 6 (Sousedství)

Řekneme, že vrcholy $u, v \in V$ v grafu $G = \langle V, E \rangle$ spolu *sousedí*, pokud existuje mezi nimi hrana $e \in E$. Říkáme, že vrcholy u, v jsou *incidentní* s e . *Sousedství* vrcholu $v \in V$ je množina vrcholů $N(v)$ obsahující všechny vrcholy, se kterými vrchol v sousedí.

Definice 7 (Stupeň vrcholu)

Stupněm vrcholu $u \in V$ v grafu $G = \langle V, E \rangle$ se rozumí počet hran s ním incidentních. Značíme jej $\deg(u)$.

Vrcholy se stupněm 1 se v teorii grafů nazývají *koncové* vrcholy, nebo *listy*. Vrcholy se stupněm 0 se nazývají *izolované*. Stupeň vrcholu u lze v orientovaném grafu dále rozdělit podle hran vcházejících a vycházejících na *vstupní stupeň vrcholu* u definovaný jako $\deg_{in}(u) = |\{\langle v, u \rangle | v \in V\}|$ a *výstupní stupeň vrcholu* u definovaný jako $\deg_{out}(u) = |\{\langle u, v \rangle | v \in V\}|$.

Definice 8 (Podgraf)

Podgraf grafu $G = \langle V, E \rangle$ je graf $H = \langle V_1, E_1 \rangle$, kde $V_1 \subseteq V$ a $E_1 \subseteq E$, tak že každá hrana z E_1 má oba vrcholy ve V_1 .

Neformálně podgraf vznikne z původního grafu odstraněním některých hran, nebo vrcholů spolu s jejich incidentními hranami. Podgraf $H = \langle V_1, E_1 \rangle$ nazveme *indukovaný*, pokud E_1 obsahuje všechny hrany z E , pro které platí, že mají oba konce v množině V_1 .

Definice 9 (Sled)

Sled v grafu $G = \langle V, E \rangle$ je sekvence vrcholů a hran tvaru $v_0, e_1, v_1, e_2, \dots, e_n, v_n$, kde vrchol $v_i \in V$ pro všechna $i \in \{0, 1, 2, \dots, n\}$ a pro hranu e_i platí:

- $e_i = \{v_{i-1}, v_i\} \in E$ pro všechna $i \in \{1, 2, \dots, n\}$, je-li G neorientovaný.

- $e_i = \langle v_{i-1}, v_i \rangle \in E$ pro všechna $i \in \{1, 2, \dots, n\}$, je-li G orientovaný.

Definice 10 (Cesta)

Cesta je sled, kde se vrcholy ani hrany neopakují

V neohodnocených grafech má cesta obsahující $n + 1$ vrcholů délku n . Délka cesty v ohodnoceném grafu je rovna součtu ohodnocení hran na cestě.

Definice 11 (Kružnice)

Kružnice je cesta, kde počáteční a koncový vrchol je stejný. U orientovaného grafu používáme pojem *cyklus*.

Definice 12 (Vzdálenost)

Pro vrcholy u, v grafu G definujeme *vzdálenost* vrcholu u a vrcholu v definujeme jako délku cesty z u do v , která je ze všech délek cest z u do v nejmenší. Značíme ji $dist(u, v)$.

Definice 13 (Souvislý graf)

Neorientovaný graf $G = \langle V, E \rangle$ nazýváme *souvislý* pokud pro každé dva vrcholy $u, v \in V$ platí, že existuje cesta z u do v . *Komponenta grafu* G je každý jeho maximální souvislý podgraf. U orientovaného grafu $H = \langle V_H, E_H \rangle$ rozlišujeme slabou a silnou souvislost. Graf H je *slabě souvislý*, pokud jeho symetrizace je souvislý graf. O grafu H řekneme, že je *silně souvislý*, pokud pro každé dva vrcholy $u, v \in V_H$ platí, že existuje cesta z u do v .

Definice 14 (Strom)

Strom je souvislý graf $G = \langle V, E \rangle$ neobsahující kružnice. Množina navzájem nepropojených stromů se nazývá *les*.

Definice 15 (Kořenový strom)

Kořenový strom je dvojice $T = \langle G, r \rangle$, kde $G = \langle V, E \rangle$ je strom a $r \in V$. Vrchol r nazýváme *kořen*.

S kořenovými stromy se pojí další pojmy. *Hloubka vrcholu* v ve stromě T s kořenem r je rovna $dist(r, v)$. Speciálně hloubka kořene r je 0. *Výškou kořenového stromu* T rozumíme nejdelší vzdálenost z kořene do některého z vrcholů v T . Vrchol v nazýváme *předchůdce* (rodič) vrcholu u , pokud v kořenovém stromu T existuje cesta z kořene r do u ve tvaru $r \dots, v, e, u$. Vrchol u se pak nazývá *následník* (přímý potomek) v . Pokud vrchol v se vyskytuje na cestě z kořene do u , nazýváme vrchol v *předek* u a vrchol u *potomek* v . Vrcholy mající stejného rodiče označujeme jako *sourozence*. *Listem* nazýváme vrchol, který v kořenovém stromu nemá žádné následníky. Naopak *vnitřní vrchol* je nazýván ten vrchol, který není listem.

2 Modelování grafových dat


POZNÁMKA 16 (PŘEKLAD)

V práci je použito české slovo “vlastnosti” přeložené z anglického slova “properties”, se kterým se běžně uživatel setká při práci s grafovou databází. Slovo “label” je z důvodu znělosti zachováno v původním znění.

Modelování dat je proces, který překládá entity reálného světa a vztahy mezi nimi do jejich softwarové reprezentace. Uživatel popisuje doménu jako graf skládající se z vrcholů a hran pomocí vlastností a labelů. Každý model je unikátní. Podoba výsledného modelu vždy závisí na případech použití a otázkách, které mají podobu dotazů, které budou na databázi kladeny. Dodržení základních principů modelování dat je důležité pro výslednou efektivitu. Když je graf přizpůsoben dotazům, dokáže velmi rychle nalézt potřebnou odpověď. Naopak špatně zvolený model grafu může ve výsledku aplikaci ublížit a být překážkou. Například tím, že zpracování dotazu bude trvat déle než u optimalizovaného modelu. Další důležitou věcí, na kterou je potřeba myslet, je budoucnost vyvíjené aplikace. Model by měl být připravený na změny, které po aplikaci budou její koncoví uživatelé požadovat. Správnému modelu je proto dobré věnovat dostatečné množství času a dodržovat obecná pravidla při jeho vytváření.

Je potřeba také podotknout, že ne všechna data jsou vhodná pro uchovávání v grafové podobě. Rozhodnutí, zda pro naše účely je grafová databáze dobrým řešením, je ve spoustě případů náročné. Existují různé typy databází (například relační, dokumentové, nebo klíč-hodnota), kde každá má své silné a slabé stránky a je potřeba si dobře promyslet, kterou zvolit. Lze dohledat spoustu “návodů” pomáhajících s touto volbou. Na Obrázku 1 je ukázán rozhodovací strom z knihy *Graph Databases IN ACTION*. Grafové databáze jsou výhodné pro aplikace, které mají vztahy mezi entitami na prvním místě. Tato vlastnost by měla být odrazovým můstkem při rozhodování, zda použít, či nepoužít grafovou databázi.

Pokud se pro požití grafové databáze rozhodneme, můžeme přistoupit k modelování dat. V této kapitole se tedy zaměříme na návrh grafového modelu. Zkusíme si to na příkladu sociální platformy pro nadšence cestování. Pracovně ji nazveme *Travel Enthusiast Network*. Sociální sítě jsou totiž jedním z případů, kdy použití grafových databází dává smysl. Tato aplikace tedy bude umožňovat cestovatelům se propojit s ostatními. Dále bude zaznamenávat jejich výlety do různých destinací, hodnocení těchto cest, cestovatelské aktivity, které destinace nabízí a které se mohou uživatelům aplikace líbit. Na základě svých přátel a hodnocení cest do destinací aplikace dokáže uživateli doporučit jiné destinace, které dosud nenavštívil. Naše aplikace se tedy bude dotýkat i dalšího případu užití grafových databází, a to systémů pro doporučování, které jsou v praxi hojně využívány. Pro vyzkoušení dotazů můžeme využít csv souborů, obsahujících vygenerovaná data pro naši aplikaci. Seznam všech souborů, rozdělený na entity a vztahy mezi nimi a počet řádků (včetně hlavičky) jednotlivých souborů lze vyčíst z Tabulky 1.



Obrázek 1: Rozhodovací strom pro otázku: Je pro naši aplikaci grafová databáze vhodná?

Typ	Název souboru	Počet řádků	Informace o souboru
Entity	activities.csv	49	Aktivity, které mohou destinace nabízet.
	countries.csv	58	Státy, v kterých se vyskytují jednotlivé destinace.
	destinations.csv	204	Destinace, které mohou uživatelé navštívit.
	journeys.csv	297	Cesty, v rámci kterých uživatelé navštěvují destinace.
	ratings.csv	641	Hodnocení jednotlivých cest uživateli.
	users.csv	301	Uživatelé sociální sítě Travel Enthusiast Network.
Vztahy	follows.csv	5738	Vztah mezi uživateli.
	is_within.csv	204	Vztah mezi destinacemi a státy.
	led_to.csv	1442	Vztah mezi cestami a destinacemi.
	likes.csv	1517	Vztah mezi uživateli a cestovními aktivitami.
	lives_in.csv	301	Vztah mezi uživateli a destinacemi.
	offers.csv	2023	Vztah mezi destinacemi a cestovními aktivitami.
	participated.csv	1518	Vztah mezi uživateli a jejich cestami.
	wrote_about.csv	641	Vztahy mezi uživateli, recenzemi a cestami.

Tabulka 1: Tabulka obsahující soubory vygenerovaných dat pro aplikaci pro cestovní nadšence.

Postup modelování se dá rozdělit do čtyř fází:

1. Definice problému
2. Konceptuální datový model
3. Logický datový model
4. Testování modelu

V následujících částech se na jednotlivé fáze podíváme detailněji.

2.1 Definice problému

V první fázi bychom měli zvážit co všechno by měla aplikace umět. Výsledkem by měl být její, co nejpřesnější, slovní popis. Pomoci nám může těchto pár otázek.

2.1.1 Co od naší aplikace uživatel očekává?

Aplikace je sociální síť, proto by měla jistě umožnit se propojit s ostatními uživateli aplikace. Uživatelům by na základě jejich přátel, oblíbených aktivit a hodnocení destinací měly přicházet tipy na výlet. Aplikace by měla umožnit zaznamenat, že někteří uživatelé podnikli cestu společně.

2.1.2 Jaké typy informací naše aplikace potřebuje uchovávat, aby měla danou funkcionalitu?

- Všechny základní informace o **uživateli**, aby se s nimi ostatní mohli spojit - jejich jméno, příjmení, unikátní identifikátor, oblíbené cestovatelské aktivity.
- Informace o jednotlivých **destinacích** - jejich lokace, název, unikátní identifikátor, cestovatelské aktivity v rámci destinace.
- Uživateli je umožněno psát **hodnocení** jednotlivých **cest**, které podniknul.
- Chtěli bychom také umožnit **seskupení uživatelů**, když jedou do dané destinace společně.

V reálném scénáři by projekt pravděpodobně zahrnoval mnoho dalších atributů, ale pro tuto ukázkovou aplikaci to ponecháme omezené. Pro zjednodušení se vyhneme také přesným souřadnicovým informacím a vystačíme si s informací v rámci jakého státu se daná destinace nachází.

Aplikace by tedy měla zacházet s pojmy jako jsou uživatel, destinace, hodnocení, cestovní aktivita.

2.1.3 Jak spolu tyto pojmy vzájemně souvisí v rámci aplikace?

- Uživatel **sleduje** jiného uživatele.
- Uživatel **se zúčastnil** cesty **do** destinace.
- Uživateli se **líbí** cestovatelská aktivita.
- Uživatel **napsal** recenzi **o** cestě.
- Destinace **nabízí** cestovatelskou aktivitu.
- Destinace **je ve** státě.

2.1.4 Na jaké otázky potřebují uživatelé najít odpověď?

- Jaké všechny uživatele sleduji? A koho sledují oni? Které uživatele nesleduji ale sledují je uživatelé, které sleduji?
- Najdi 3 nejlépe hodnocené destinace, které jsem nenavštívil, nabízející konkrétní cestovní aktivity?
- Které destinace navštívil uživatel X. Kolikrát je navštívil?
- Najdi mi všechny uživatele v rámci skupiny, s kterou cestuje uživatel X do destinace Y.
- Najdi X destinací nabízející některé z cestovatelských aktivit, které se uživateli líbí.
- Pro konkrétní destinaci vrať měsíc v roce v kterém je nejlépe hodnocená.
- V kterých destinacích a před kolika lety jsem byl v tento konkrétní den a měsíc?

V reálném scénáři by otázek mohlo být mnohem více.

2.2 Konceptuální datový model

Dalším krokem je vyvinout konceptuální model. Výstupem by měl být přehledný diagram popisující důmyslně promyšlené schéma naší aplikace z bussiness pohledu. Vyvarujeme se v něm pro nevyvojáře zbytečným detailům a zaměříme se pouze na to, jak data různých typů v rámci vyvíjené aplikace spolu souvisí. Při vyvíjení datového modelu vývojáři často kreslí na tabuli, jak jsou data v rámci projektu propojena s dalšími daty, proto se tato fáze v různých literaturách nazývá whiteboard model. Tento proces vyžaduje identifikování a seskupení všech entit a vztahů, které se v naší aplikaci vyskytují.

2.2.1 Entity

Začneme entitami. Entity většinou představují objekty, jako například uživatel, účet, destinace, které jsou v databázi uloženy a propojeny vzájemnými vztahy. Je třeba si rozmyslet, které entity lze seskupit. Pokud například naše aplikace obsahuje uživatele, zaměstnance a administrátory je užitečné tuto skupinu entit sloučit do jedné a pojmenovat ji například Osoba. Jedním z osvědčených postupů, jak z našich poznámek z minulé fáze vytáhnout entity, je dívat se po podstatných jménech. Pokud se budeme řídit tohoto postupu, tak z věty “Uživateli se líbí cestovatelská aktivita.” získáme dvě entity, a to Uživatel a Cestovatelská aktivita.

V naší aplikaci můžeme dohromady rozpoznat 6 různých entit:


- Uživatel
- Cesta
- Destinace
- Aktivita
- Stát
- Recenze

Seskupení uživatelů cestujících spolu do destinací jsme sloučili s entitou Cesta. Jedná se o mírné zjednodušení, které nebude mít na funkčnost žádný velký vliv.

2.2.2 Vztahy

Nyní následuje propojení entit pomocí vztahů. Entity v rámci naší aplikace jsme identifikovali zejména zaměřením se na podstatná jména z poznámek o aplikaci. Vztahy můžeme získat obdobně pomocí sloves. Zde bychom však měli být velmi opatrní. Ve slovese se často ukrývá podstatné jméno. V budoucím vývoji aplikace by pak mohlo dojít k problémům při rozšiřování funkcionality aplikace. Dobrým příkladem je sloveso “recenzovat”. Pokud bychom při modelování zvolili větu “Uživatel recenzoval X.” místo “Uživatel napsal recenzi o X.”, tak bychom mohli v budoucím vývoji aplikace narazit na problém, že nemáme entitu představující recenzi, na kterou bychom mohli odkazovat. Snadno si jde domyslet komentování nebo jiný způsob reagování na recenze. Podobně pokud bychom v naší aplikaci upřednostnili větu “Uživatel navštívil destinaci.” před větou “Uživatel podnikl cestu do destinace.”, uživatel by pak nemohl danou cestu hodnotit tak, jak to máme v popisu naší aplikace. Takové chyby obecně vedou v budoucnosti k migrování databáze, což je velmi obtížný a zdlouhavý proces přesouvání dat z jedné databáze do druhé, kterému je lepší se vyhnout.

Hledáme tedy slovesa, které představují relaci mezi námi nalezenými entitami. Po aplikaci této poučky na větu “Uživateli se líbí cestovatelská aktivita.” získáme vztah “se líbí” mezi entitami Uživatel a Cestovatelská aktivita. Stejným způsobem postupujeme dál a hledáme všechny důležité vztahy. Může se stát, že



Obrázek 2: Konceptuální datový model pro sociální síť pro cestovní nadšence

při důkladném hledání vztahů nalezneme další entity, které jsme předtím nenašli.

Po důkladném rozmyšlení má naše tabule stejný obsah, jako na Obrázku 2.


2.3 Logický datový model

Pokud jsme s diagramem z předchozí fáze spokojeni, můžeme konečně přistoupit ke kroku, ve kterém definujeme schéma, které bude v databázi. V případě relačního modelování je konceptuální model přeformátován, aby mohl být ukládán do tabulek. V případě grafového modelování toto není potřeba. Stačí identifikovat vrcholy a hrany a přiřadit jim příslušný label a vlastnosti. Výstupem tedy bude opět diagram, který ale bude mnohem detailnější. Bude se zabývat detaily, kterými se zabývají vývojáři. Bude definovat tvar, ve kterém budou data v databázi uložena a podle něj budeme moci klást na databázi dotazy.

Pro vytvoření grafového modelu jsou potřeba tyto 3 kroky:

1. Převést entity na vrcholy
2. Převést relace na hrany
3. Najít a přiřadit vlastnosti vrcholům a hranám

První jsou na řadě vrcholy. Podstatnou část práce již máme za sebou, neboť můžeme využít konceptuální model a namapovat entity na vrcholy. Zbývá jen



Obrázek 3: Label vrcholu definuje do které kategorie vrchol spadá

jeden netriviální úkol - každému vrcholu přiřadit krátký, přesný a výstižný label. Label vrcholu určuje, do které skupiny nebo kategorie vrcholů patří. Všechny vrcholy se stejným labelem pak spadají do stejné kategorie. Pro lepší pochopení je zde Obrázek 3. Label pak můžeme používat v dotazech na databázi a pracovat tak s různými skupinami vrcholů a dosáhnout tak lepšího výkonu při dotazování.

Při vymýšlení labelu musíme mít jako vždy na paměti budoucí rozšiřitelnost a fakt, že s databází může pracovat jiný vývojář. Dobře zvolený label je tedy velmi žádaný. Důležité je též dbát na pojmenovovací konvenci.

POZNÁMKA 17 (KONVENCE POJMENOVÁNÍ)

V našem příkladu je zvolena konvence doporučená v dokumentaci databáze Neo4j a tedy pro labely vrcholů budeme používat UpperCamelCase notaci, pro labely hran UPPER_CASE notaci s použitím podtržítka pro oddělení slov (SCREAMING_SNAKE_CASE) a pro vlastnosti camelCase notaci.

Dobрым zvykem je zvolit label, který bude v jednotném čísle, neboť každý vrchol odkazuje na jednu instanci vrcholu s daným labelem. Při přiřazování labelu je dobré myslet na jeho co největší obecnost, protože v budoucnu bychom mohli potřebovat reprezentovat jiný podobný koncept a tedy je užitečné volit co nejobecnější label.

Povolený počet labelů vrcholu se u různých grafových databází liší. Bezpečným přístupem je každému vrcholu přiřadit jeden label. To je například přístup Apache TinkerPop. Často se ale také hodí mít labelů víc a pomocí nich umět


vyjádřit dědičnost. Pokud bychom spravovali zaměstnance v nějaké firmě, hodilo by se někdy k labelu “Zaměstnanec” mít label “Ředitel“, “Manažer“ apod. Tyto vrcholy pak spadají do více skupin vrcholů naráz. Proto například Neo4j nebo Amazon Neptune umožňují vrcholům přiřadit žádný, jeden ale i více labelů.

Při hledání hran opět využijeme důsledně připraveného konceptuálního modelu. Znovu se zamyslíme nad pojmenováním hran, které by opět mělo být obecné a výstižné. Navíc bychom se měli držet jedné dobré zásady. Přechzení posloupnosti vrcholu, hrany z něj vycházející a vrcholu do nějž hrana vstupuje by nám mělo dávat vcelku smysluplnou větu. V češtině však musíme opomenout skloňování. Tedy například “Uživatel napsal hodnocení.“, nebo “Uživatel sleduje uživatele.“. To nás přivádí k orientaci hran. Předchozí rada nám tedy specifikuje orientaci hrany, neboť obrácením hrany bychom dostali věty “Hodnocení napsalo uživatele.“, nebo “Uživatel sleduje uživatele.“. V druhém případě se nám smysl věty nezměnil, jelikož se jedná o smyčku jdoucí z jednoho vrcholu do toho samého vrcholu. V prvním případě, kdy bychom požadovali opačnou orientaci hran mezi vrcholy “Uživatel“ a “Hodnocení“, bychom museli přistoupit ke změně labelu hrany, neboť by věta postrádala smysl. Tedy například hraně “napsal“ bychom změnili label na “bylo napsáno“ a pak by věta “Hodnocení bylo napsáno uživatelem.“ dávala smysl.

Než přejdeme k vlastnostem, zbývá ještě určit jedinečnost hran. Jedinečnost lze definovat jako počet hran se stejným labelem mezi dvěma vrcholy. Tyto vrcholy mohou a nemusí mít stejný label. Jedinečnost hran se dělí na dva typy jednoduchou a mnohonásobnou. Jednoduchá odkazuje na žádnou, nebo právě jednu hranu zatímco vícenásobná povoluje hran se stejným labelem mezi dvěma vrcholy více. Co se týká jedinečnosti hran v naší aplikaci tak všechny hrany, až na hranu mezi Cestou a Destinací budou mít jedinečnost jednoduchou. Mezi uživatelem a cestovní aktivitou vztah “LIKES“ buď je nebo není a to lze vyjádřit pomocí existence jedné hrany mezi těmito dvěma vrcholy. Totéž platí pro ostatní hrany až na hranu s labelem “LED_TO“. Jistě totiž existuje situace, kdy v rámci cesty uživatel do dané destinace zavítá vícekrát a s touto možností by náš model měl také počítat. Tedy tato hrana bude mít vícenásobnou jedinečnost. Tyto hrany pak od sebe rozlišíme pomocí vlastností, které budou určovat období, kdy se daný uživatel v dané destinaci nacházel.

Jak zjistíme, že jsme zvolili špatnou jedinečnost hran? Špatná volba se projeví v dotazech jedním z těchto způsobů:

- Databáze vrací příliš málo dat. Tato chyba nastane pokud zvolíme jednoduchou jedinečnost hran tam, kde by měla být zvolena vícenásobná jedinečnost.
- Databáze vrací duplikativní data. Tato chyba nastane pokud zvolíme vícenásobnou jedinečnost hran tam, kde by měla být zvolena jednoduchá jedinečnost.
- Slabý výkon dotazů na databázi. Tato chyba nastane pokud zvolíme vícenásobnou jedinečnost hran tam, kde by měla být zvolena jednoduchá jedi-



Obrázek 4: Logický datový model pro sociální síť pro cestovní nadšence

nečnost. Každá hrana stejného labelu mezi dvěma vrcholy navíc znamená rozvětvení v případě průchodu grafem a zvyšuje tedy výslednou časovou složitost dotazu.

U některých implementací grafových databází, jako například DataStax Graph nebo JanusGraph, lze tuto jedinečnost vynutit jako součást při definování schématu. U implementací bez schématického přístupu, jako je Neo4j, tuto jedinečnost lze ošetřit pouze v rámci aplikace.

Poslední zastávkou při konstruování logického modelu jsou vlastnosti. Základní kameny grafu vrcholy a hrany máme, ale chybí nám způsob jak rozlišit vrcholy se stejným labelem. K tomu slouží vlastnosti. V grafových databázích mohou mít vlastnosti jak hrany tak vrcholy, neboť hrany jsou pro nás stejně významné jak vrcholy. Vlastnosti v grafové databázi jsou páry klíč-hodnota a popisují konkrétní atributy hrany, či vrcholu. Hodnota vlastnosti může být různého datového typu, například řetězec, číslo, pravdivostní hodnota nebo datový typ pro uchování datumu a času. Někdy též může být hodnota typu pole nebo seznam. Pomocí vlastností následně můžeme rozlišit jednotlivé uživatele pomocí jejich křestního jména, příjmení, uživatelské přezdívky apod. K dokončení logického modelu nám tedy zbývá najít a správně přiřadit vlastnosti konkrétním vrcholům a hranám, pojmenovat je a určit jejich datový typ. K jejich nalezení nám pomohou otázky, které budeme chtít, aby nám databáze zodpověděla. Z nich můžeme jednotlivé vlastnosti identifikovat a přiřadit.

Náš výsledný datový model popisuje Obrázek 4.

Typ	Název souboru	Počet řádků
Entity	stations.csv	560
Vztahy	leads_to.csv	1386

Tabulka 2: Tabulka obsahující soubory pro ukázkou hledání cest.

2.4 Testování modelu

V budoucnu je možné přidat entitu cestovní kanceláře, která bude pořádat cesty do destinací a uživatelé po objednání budou do této cesty připojeni. To otevírá dveře dalším entitám například pro hodnocení cestovních kanceláří, nebo vztahům které se týká zaměstnanosti uživatelů u dané cestovky.

Testování našeho grafového modelu spočívá ve vyzkoušení, zda se chová dle našeho očekávání (databáze vrací očekávané výsledky) a dotazování není moc pomalé ani pro velké množství dat. K testování lze využít široké škály nástrojů, které dotazovací jazyky a databáze nabízejí.

Při testování dotazů je vhodné použít tzv. unit testy. Tedy vytvoříme si pro každý dotaz malé množství testovacích dat (například kolem 10 vrcholů, tak abychom z něj pouhým okem vyčetli správnou odpověď), kterými otestujeme správnost odpovědí z databáze. Příklad unit testu je na Obrázku... **TODO**

3 Hledání cest mezi 2 vrcholy


V této kapitole si odhalíme další velkou výhodu grafových databází a to hledání cest mezi vrcholy. V první části si připomeneme dva základní algoritmy pro průchod grafem a následně této znalosti využijeme ve druhé části při zjišťování dosažitelnosti a hledání nejkratších cest ve smyslu počtu hran mezi dvěma vrcholy. Ve třetí části se podíváme na hledání cesty s nejmenším možným součtem ohodnocení hran na této cestě.

Pro ukázkové příklady je použitý dataset obsahující informace o belgických železničních stanicích a spojeních mezi nimi. Jednoduchý model znázorňuje Obrázek 5. V databázi tedy budeme uchovávat tedy pouze vrcholy s labellem Station a hrany mezi nimi s labellem LEADS_TO. Původní dataset je rozdělen do dvou csv souborů. Jeden uchovává informace o železničních stanicích a druhý spojení mezi nimi. Informace obsahující souřadnice pro jednotlivá spojení byly vypuštěny. Seznam souborů shrnuje Tabulka 2.


3.1 Procházení grafu

Pro prohledávání grafů od určitého počátečního vrcholu lze použít dva známé grafové algoritmy:

1. Prohledávání do šířky (zkráceně BFS z anglického spojení Breadth-first search)



Obrázek 5: Model grafové databáze pro ukázkové příklady v této kapitole




Obrázek 6: Průchod algoritmu BFS grafem.

2. Prohledávání do hloubky (zkráceně DFS z anglického spojení Depth-first search)

Oba algoritmy mají složitost $O(|E| + |V|)$.

Algoritmus BFS začne v počátečním vrcholu a následně prohledá všechny své sousední vrcholy. Poté projde sousedy sousedů počátečního vrcholu, které ještě nenavštívil a tak postupuje dokud nenavštíví všechny dosažitelné vrcholy. Tento způsob procházení grafu lze znázornit pomocí kořenového stromu. Kořenem je počáteční uzel. Algoritmus prochází vrcholy grafu po jednotlivých úrovních tohoto stromu. Platí, že nejkratší cesta z počátečního vrcholu do vrcholu v v grafu je rovna hloubce v ve stromu, který vznikne průchodem do šířky. Lze jej efektivně implementovat pomocí fronty vrcholů. Průchod grafem do šířky a strom, vzniklý průchodem algoritmu jsou znázorněny na Obrázku 6. Pořadí, v kterém jsou vrcholy procházeny je znázorněno čísla v obdélnících u každého vrcholu.

Algoritmus DFS postupuje opačně, v aktuálně navštíveném vrcholu přejde do dosud nenavštíveného souseda, pokud takový soused existuje, jinak provede backtracking – vrací se zpět po cestě odkud přišel, dokud nenalezne vrchol jehož soused nebyl navštíven. Skončí jakmile jsou všechny vrcholy navštíveny. Tento způsob procházení grafu lze opět znázornit pomocí kořenového stromu, kde ko-



Obrázek 7: Průchod algoritmu DFS grafem.

řem je počáteční uzel. Avšak v tomto stromu pozorování ohledně nejkratších cest, jaké jsme udělali u BFS obecně neplatí. Při implementaci využíváme zásobník. Průchod grafem do hloubky a strom, vzniklý průchodem algoritmu jsou znázorněny na Obrázku 7. Pořadí, v kterém jsou vrcholy procházeny je znázorněno čísly v obdélnících u každého vrcholu.

3.1.1 Cesta v neohodnoceném grafu

Na tento typ cesty lze nahlížet jako na cestu v grafu, kde každá hrana má stejnou váhu. Tyto cesty lze hledat i v grafu s ohodnocenými hranami tak, že ohodnocení hran ignorujeme. Počet hran na cestě pak určuje délku cesty. Avšak cest mezi dvěma vrcholy může být obrovské množství. Pokud neomezíme průchod grafem, například pomocí hledání cesty fixní délky, nebo maximální možným počtem hran na cestě, může se stát, že výpočet bude trvat velmi dlouho, nebo v horším případě bude nekonečný. Druhá možnost nastane pokud nezajistíme, že v grafu hledáme opravdu jen cesty a nikoliv sledy. (Cesta i sled byly definovány v první kapitole.) Výpočet by se pak zacyklil a místo výsledku bychom dostali run-time-error.

Tento problém lze vyřešit pomocí algoritmů na prohledávání grafů. Konkrétně se řeší pomocí prohledávání do šířky, neboť systematicky prochází všechny vrcholy, které mají nejkratší vzdálenost od počátečního vrcholu rovnou k , kde $k \in \mathbb{N}_0$. Začíná pro $k = 0$ a postupně k inkrementuje dokud nenarazí na cílový vrchol. S tímto přístupem je zřejmé, že pokud je cílový vrchol dosažitelný ze začínajícího vrcholu, pak v neohodnoceném grafu nalezneme nejkratší cestu. Pro libovolné $k \in \mathbb{N}$ můžeme takto postupovat i pro nalezení k různých nejkratších cest pro dva dané vstupní vrcholy. V případě algoritmu procházení do hloubky bychom nalezení nejkratší cesty obecně dosáhnout nemuseli, i když by řešení mohlo být rychlejší, pokud by se algoritmus vydal správným směrem. To lze opět usoudit z toho, jak je algoritmus implementován. Tedy tento algoritmus je

Index	Stations
0	["BILZEN", "DIEPENBEEK", "HASSELT", "SCHULEN"]
1	["BILZEN", "BOKRIJK", "KIEWIT", "SCHULEN"]
2	["BILZEN", "DIEPENBEEK", "HASSELT", "KIEWIT", "SCHULEN"]
3	["BILZEN", "DIEPENBEEK", "HASSELT", "ZONHOVEN", "SCHULEN"]
4	["BILZEN", "BOKRIJK", "KIEWIT", "HASSELT", "SCHULEN"]

Tabulka 3: Výsledná tabulka pro dotaz 1

možné využít k zjištění dosažitelnosti vrcholu, což může být v určitých případech výhodné, pokud jsou vrcholy od sebe hodně vzdálené.

V Cypheru lze cesty obsahující 1 až 4 hrany najít pomocí dotazu 1. Na řádku 2 vyfiltrujeme ty sledy, které obsahují cyklus. Pro lepší přehled výsledky oindexujeme a seřadíme podle délky cesty. Tabulka 3 ukazuje výsledek tohoto dotazu po zavolání. Obrázek 8 pak znázorňuje podgraf, který obsahuje všechny vrcholy a hrany vystupující v dotazu. Tučnou čarou je zde znázorněna cesta, která ve výsledné tabulce má index 3. Čárkovaně je vyznačena cesta označená v tabulce indexem 1.

```


1 MATCH path=(src:Station {stationId: 157})-[:LEADS_TO*1..4]->(dst:
   Station {stationId: 1061})
2 WHERE ALL(node IN nodes(path) WHERE 1 = size([n IN nodes(path) WHERE
   n = node]))
3 WITH path, [node IN nodes(path) | node.stationName] AS stations
4 ORDER BY size(stations)
5 WITH COLLECT(stations) AS allStations
6 UNWIND range(0, size(allStations) - 1) AS index
7 RETURN index, allStations[index] AS stations;
```

Zdrojový kód 1: ukázkový kód v Cypheru

3.1.2 Cesta v ohodnoceném grafu

Délka cesty mezi počátečním a koncovým vrcholem v ohodnoceném grafu je určena součtem ohodnocení hran na cestě. Tedy nejmenší počet hran na cestě nutně neznamená, že součet ohodnocení hran je menší než na jiné cestě obsahující více hran. Z tohoto důvodu nemůžeme použít lehce modifikovaný algoritmus, který nám řešil problém v předchozí části. Zde též platí, že cest může být mezi dvěma vrcholy opravdu mnoho. Obzvláště ve velikých grafech. Z těchto důvodů Neo4j nabízí knihovnu optimalizovaných algoritmů, která hledání nejkratší cesty v ohodnoceném grafu nabízí. Na tuto knihovnu se podíváme v další kapitole.

Často se z časových důvodů nejkratší cesta aproximuje. Pokud má vrchol na možné cestě výstupní stupeň větší než nějaký limit l (například $deg_{out}(u) >$



Obrázek 8: Podgraf reprezentující výsledek dotazu 1.

10000), cestu přes něj nepočítáme, neboť bychom museli procházet každou výstupní hranu což by bylo výpočetně náročné. Těmto vrcholům se říká super-uzly. Více o nich si řekneme v následující kapitole.

Výpočet lze optimalizovat zadáním horního limitu pro délku cesty. Pokud délka cesty tento limit přesáhne, tak tato cesta je zavrhnuta. Další optimalizaci si lze vypůjčit od Dijkstrova algoritmu, a to tu že si budeme udržovat a aktualizovat nejkratší dosud nalezenou cestu do navštívených vrcholů. Tato optimalizace je využita v dotazu 2 v jazyku Gremlin.

Po zavolání obdržíme tento výsledek.

```

==>[stations:[SCHAERBEEK,BUDA,VILVOORDE,EPPEGEM,WEERDE,MECHELEN,SAUV,BOOM,NIEL,SCHELLE],verticesPlusEdges:23,totalLength:47.2919646501541135]
==>[stations:[SCHAERBEEK,VILVOORDE,EPPEGEM,WEERDE,MECHELEN,WILLEBR,SAUV,BOOM,NIEL,SCHELLE],verticesPlusEdges:21,totalLength:47.3549143075942987]
==>[stations:[SCHAERBEEK,MECHELEN,WILLEBROEK,PUURS,RUISBR,SAUV,BOOM,NIEL,SCHELLE],verticesPlusEdges:15,totalLength:48.9187709093093871]

```

Z vrácených výsledků vidíme, že nejkratší délka železnic mezi stanicemi SCHAERBEEK a SCHELLE má délku 47.3 kilometrů. Na této cestě mezi stanicemi je 10 zastávek. Jen o 50 metrů je delší druhá cesta, která obsahuje o jednu zastávku méně. Třetí výsledek je delší o necelé 2 kilometry a má 6 zastávek.

```

1  g.withSack(0.0).
2    V().
3    has("Station", "stationId", 1048).
4    repeat(outE("LEADS_TO").
5      sack(sum).by("length").
6      inV().as("visited").
7      simplePath().
8      group("minDist").
9      by().by(sack().min()).
10     filter(project("currMinDist", "sackDist").
11       by(select("minDist").select(select("visited"))).
12       by(sack()).
13       where("currMinDist", eq("sackDist")))).
14    until(has("Station", "stationId", 1066)).
15    order().
16     by(sack(), asc).
17    limit(3).
18    project("stations", "verticesPlusEdges", "totalLength").
19     by(path().
20       unfold().
21       hasLabel("Station").
22       values("stationName").
23       fold()).
24     by(path().count(local)).
25     by(sack())

```

Zdrojový kód 2: ukázkový kód v dotazovacím jazyku Gremlin

4 Algoritmy

V této kapitole si ukážeme řadu užitečných algoritmů, které jsou určené pro práci s grafem a jsou tedy v určitých situacích vhodné aplikovat při dotazech na grafovou databázi. Umožňují nám efektivně zjistit hledat nejkratší cesty mezi vrcholy, nacházet vrcholy, které pro nás mohou být svým způsobem důležité, nebo třeba analyzovat komunity (skupinky propojených vrcholů) v grafu. Ke grafové databázi Neo4j existuje knihovna s názvem Graph Data Science Library nabízející veškeré algoritmy, které lze po nainstalování pluginu použít. Zkráceně ji budeme označovat gds jako v dotazech Neo4j. V následujících částech si představíme užití pár algoritmů z této knihovny.

4.1 Algoritmy pro hledání cesty v grafu

V praxi je užitečné v grafu najít rychle optimální cestu mezi dvěma, či více vrcholy. Tento problém potřebují řešit například nástroje pracující s grafy reprezentující mapy, které hledají vhodné trasy mezi body na mapě. Dalšími příklady optimalizačních problémů jsou řízení dodavatelských řetězců, hledání nejvhodnějšího autobusového spojení a analýza počítačové sítě.

Pro řešení tohoto problému vznikly různé algoritmy, hledající optimální výsledek. Každý pracuje odlišně a je výhodný pro různé poddruhy problémů. Pár z nich si zde představíme.

4.1.1 Dijkstra

Jeden z nejznámějších algoritmů pro hledání nejkratší cesty. Lze jej aplikovat na neohodnocené grafy, nebo grafy s kladným ohodnocením hran. Jedná se o hladový algoritmus, který k specifikovanému vrcholu vydá nejkratší cestu z tohoto vrcholu do všech ostatních vrcholů. Lze jej také omezit, aby iteroval jen dokud nenajde nejkratší cestu ke konkrétnímu cílovému vrcholu. Dosáhne správného řešení díky pamatování dosud nejkratších nalezených cest do již navštívených vrcholů. V každé iteraci pak vybere jeden vrchol s nejkratší nalezenou cestou ze všech, které dosud nebyly vybrány a následně aktualizuje všechny nejkratší cesty vedoucí přes tento vybraný vrchol. Pokud je nějaký vrchol nedosažitelný nebo ještě nebyl navštívený, má hodnotu ∞ . Nevýhodou tohoto algoritmu je, že pro nalezení nejkratší cesty pro 2 zadané vrcholy je v nejhorším případě potřeba nalézt všechny nejkratší cesty do ostatních vrcholů, než se algoritmus dostane k požadovanému výsledku. To nastává v případě, kdy mezi dvěma vrcholy je nejkratší cesta nejdelší ze všech nejkratších cest z počátečního vrcholu do ostatních vrcholů. Tento problém se pokouší řešit následující algoritmus.


4.1.2 A*

A* (čteme A-star) pracuje podobně jako Dijkstrův algoritmus, ale v mnoha případech ji najde rychleji. Je to protože dostane navíc na vstupu dodatečnou informaci, kterou používá při rozhodování do jakého vrcholu bude algoritmus pokračovat. Toto rozhodnutí je provedeno na základě funkce $f(n) = g(n) + h(n)$, kde funkce $g(n)$ představuje součet ohodnocení nejkratší cesty ze startu přes dosud navštívené vrcholy do n a funkce $h(n)$ je odhad délky cesty z n do cíle. Funkci $h(n)$ říkáme heuristika. V každé iteraci pak algoritmus pokračuje vrcholem, pro který je hodnota funkce f nejmenší. Pro správné výsledky by heuristika měla být optimistická, tedy odhad by měl být menší nebo roven skutečné vzdálenosti do cíle. Platí, že čím lépe odhadneme heuristiku tím rychleji algoritmus najde řešení. Pro svůj rychlý výpočet je například implementován ve videohrách. Dijkstrův algoritmus je speciálním případem A*. Pro něj platí $h(v) = 0$ pro všechny vrcholy $v \in V$.

V knihovně gds lze A* použít například pro vrcholy reprezentující nějakou lokaci, která je přesně určena pomocí zeměpisné šířky a délky. Geografické souřadnice nám slouží jako část heuristické funkce.

4.1.3 Minimální kostra grafu

Dalším, mezi informatiky dobře známým, problémem je hledání minimální kostry v souvislém grafu. Vstupem je souvislý neorientovaný graf G s ohodnocenými



Obrázek 9: Minimální kostra grafu

hranami. Výstupem je minimální kostra grafu G . Kostru grafu lze definovat jako podgraf grafu G , který je stromem obsahujícím všechny vrcholy původního grafu. My požadujeme, aby kostra byla minimální, tedy aby součet ohodnocení hran v nalezeném podgrafu byl ze všech možných koster nejmenší. Příklad minimální kostry grafu je na Obrázku 9. Problém kostry grafu má více variant. Můžeme též hledat maximální kostru grafu, nebo omezit počet vrcholů v kostře na $k \in \mathbb{N}$ tomuto problému se říká k -spanning tree. Knihovna gds algoritmus na hledání kostry obsahuje. Konkrétně nabízí Jarníkův-Primův algoritmus, poprvé popsáný v roce 1930 českým matematikem Vojtěchem Jarníkem. Jedná se o hladový algoritmus, který vyžaduje na vstupu specifikovat i počáteční vrchol s . Vrátil minimální kostru komponenty vstupního grafu obsahující s . Pokud při implementaci využíváme například binární prioritní frontu máme celkovou složitost $O(|E| \log_2 |V|)$. Tento algoritmus lze využít pro nejlevnější propojení měst vodním potrubím, kde nižší ohodnocení hran znamená menší náklady. Dalším využitím je aproximace problémů patřících do třídy NPTIME, jako je například problém obchodního cestujícího.

4.1.4 Random walk

Jak už název napovídá, Random walk provádí náhodné sledy v grafu specifikované délky. Simuluje průchod grafem přičemž náhodně vybírá hrany. V klasické verzi algoritmu je v každém vrcholu pravděpodobnost vybrání hrany uniformní a nezáleží na předchozích výběrech. Knihovna gds nabízí Random walk druhého řádu. U tohoto algoritmu se specifikují dva parametry:

- `returnFactor` - vyjadřuje tendenci algoritmu se vracet zpět k naposledy navštívenému vrcholu. Hodnoty menší než 1, pravděpodobnost tohoto výběru zvyšují.
- `inOutFactor` - vyjadřuje tendenci algoritmu zůstat či nezůstat v blízkosti počátečního vrcholu. Čím vyšší hodnota je zadána, tím bude průchod

stations
AALST, EREMBODEGEM, DENDERLEEUEW, IDDERGEM, DENDERLEEUEW, GENT-ST-P, DENDERLEEUEW, GENT-ST-P
AALTER, MARIA-AALTER, AALTER, BELLEM, HANSBEKE, BELLEM, HANSBEKE, BELLEM
AARSCHOT, BEGIJNENDIJK, AARSCHOT, LANGDORP, AARSCHOT, "BEGIJNENDIJK, AARSCHOT, LANGDORP

Tabulka 4: Výsledek algoritmu Random walk s parametrem inOutFactor nastaveným na hodnotu 2 zavolaným na stanice s vlastností stationId menší než 10.

stations
AALST, LEDE, AALST, EREMBODEGEM, DENDERLEEUEW, MELLE, KWATRECHT, WETTEREN
AALTER, BELLEM, HANSBEKE, LANDEGEM, HANSBEKE, BELLEM, AALTER, MARIA-AALTER
AARSCHOT, LANGDORP, TESTELT, LANGDORP, BEGIJNENDIJK, BOOISCHOT, HEIST-BERG, MELKOUWEN

Tabulka 5: Výsledek algoritmu Random walk s parametrem inOutFactor nastaveným na hodnotu 0.2 zavolaným na stanice s vlastností stationId menší než 10.

grafem lokálnější.

V klasické verzi jsou oba parametry nastaveny na hodnotu 1. Pravděpodobnost výběru též můžeme ovlivnit pomocí ohodnocených hran. Vlastnost hrany, která je vyšší než jedna pravděpodobnost výběru této hrany zvyšuje. Naopak hodnoty z intervalu $(0, 1)$ pravděpodobnost zmenšují.

Random walk se používá jako součást jiných algoritmů, kde je potřeba množina náhodných, ale navzájem propojených vrcholů. V následující ukázce byl algoritmus `gds.randomWalk` použit na železniční stanice, které mají vlastnost `stationId` menší než 10. To jsou stanice s vlastností `stationName` AALST, AALTER a AARSCHOT. Tabulka 4 zobrazuje výsledky s parametrem `inOutFactor` rovným 2. V tabulce 5 jsou vidět výsledky s parametrem `inOutFactor` rovným hodnotě 0.2.

4.2 Algoritmy pro míru centrality

V rámci grafu můžeme identifikovat důležitost vrcholů pomocí algoritmů centrality. Můžeme detekovat jedince, které jsou svým způsobem v grafu významější než ostatní. Tyto algoritmy se dají využít například k hledání kritických částí v telekomunikačních nebo počítačových sítích, tedy těch přes které proudí spousta informací a jejichž výpadek by představoval velké potíže. Hledání důležitých lidí v rámci organizace. Hledání odlehklých dat, které mohou odhalit, že dochází k

podvodům a podobně. Knihovna gds nabízí spoustu algoritmů pro měření centrality. My se podíváme na pár z nich.

4.2.1 Degree Centrality

Nejznámějším a nejjednodušší mírou centrality je degree centrality. Každému vrcholu v síti přiřazuje skóre podle stupně daného vrcholu. V sociálních sítích mívají vrcholy i stupně v řádu desítek milionů (jedná se o vrcholy, reprezentující účty známých osobností nebo organizací). Těmto vrcholům říkáme super-uzly. Abychom prošli všechny sousedy super-uzlu potřebujeme značně více času, než v případě obyčejného vrcholu. To se negativně projevuje v časové odezvě u dotazů pracujících s takovými vrcholy. Degree centrality nám umožňuje takové vrcholy odhalit. Vrcholy s větším stupněm také lze obecně považovat za důležitější, neboť přes ně může proudit více informací díky velkému počtu hran. Příkladem může být graf reprezentující železniční síť. Čím více máme z dané železniční stanice spojení, tím spíše se jedná o významější stanici.

4.2.2 Closeness Centrality

Vrcholy lze dále hodnotit podle closeness centrality. Vrchol s nejvyšším skóre je ten, pro který je součet nejkratších cest do všech ostatních vrcholů co nejmenší. Skóre vrcholu $u \in V$ v grafu $G = \langle V, E \rangle$ se pak počítá podle vzorce

$$closenessCentrality(u) = \frac{1}{\sum_{v \in V} dist(u, v)}, \quad (1)$$

nebo se normalizuje

$$normalizedClosenessCentrality(u) = \frac{|V| - 1}{\sum_{v \in V} dist(u, v)}. \quad (2)$$

V případě, že graf není souvislý, lze použít harmonic centrality, které se elegantně vypořádá s nedosažitelnými vrcholy. Tento a následující algoritmus mohou být v případě velkých grafů výpočetně dost náročné a tedy se často přistupuje k ne zcela přesným, zato mnohonásobně rychlejším, algoritmům.

4.2.3 Betweenness Centrality

Algoritmus spočítá nejkratší cesty mezi všemi možnými páry vrcholů. Následně každý vrchol obdrží skóre, které je tím vyšší, čím více nejkratších cest vede přes daný vrchol. Tyto hodnoty mohou pro nás být klíčové například v grafu, kde vrcholy představují křižovatky a hrany cesty mezi nimi. Informaci, kterými křižovatkami prochází nejvíce nejkratších cest, můžeme využít pro odhad těch nejvíce zatížených křižovatek. Případně díky ní můžeme odhadnout, kde se pravděpodobně bude pohybovat nejvíce lidí a tedy je potřeba zvýšit bezpečnost.

Vrchol	A	B	C	D	E	F	G
Degree Centrality	4	3	4	4	3	2	2
Closeness Centrality	0.75	0.6	0.75	0.75	0.67	0.55	0.6
Betweenness Centrality	3.33	0.0	1.33	1.33	2.67	1.0	1.33
Eigen Vector Centrality	0.45	0.41	0.49	0.49	0.32	0.14	0.17

Tabulka 6: Algoritmy pro měření centrality aplikované na jednotlivé vrcholy z grafu 10

4.2.4 PageRank


S tímto řešením přišla na trh společnost Google. Byla určena pro hodnocení významnosti webových stránek. Webové stránky si lze představit jako vrcholy grafu. Hrany mezi nimi reprezentují odkazy na stránkách odkazující na jiné stránky. Důležitost vrcholu je určena nejen důležitostí vrcholu samotného, ale také důležitostí vrcholů na tuto stránku odkazujících. Vysoké skóre vrcholu tedy znamená, že je vrchol propojen s vrcholy, které mají též vysoké skóre. Toto řešení je založeno na lineární algebře, speciálně na vlastních vektorech a stochastických maticích. Výpočet skóre většinou vede na nekonečný výpočet a proto se omezuje počet iterací tohoto výpočtu, nebo se udává maximální možná odchylka. PageRank se používá na orientované grafy. Pro neorientované grafy lze použít algoritmus eigenvector centrality.

4.2.5 Použití algoritmů pro míru centrality

Výsledky aplikace jednotlivých algoritmů pro měření centrality na graf z Obrázku 10 je znázorněn v tabulce 6.

4.3 Detekce komunit

Tyto algoritmy lze využít pro hledání určitých skupin vrcholů, které mají mezi sebou více hran, než mají s ostatními vrcholy grafu. Odhalením těchto shluků vrcholů můžeme zkoumat strukturu našich dat z jiného úhlu pohledu, nebo třeba odhadovat podobné chování a preference členů v rámci skupiny. Příklad lze nalézt v sociálních sítích, kde můžeme sledovat komunity blízkých přátel, které tvoří shluky propojených vrcholů. Znalost komunit lze též využít pro doporučování produktů uživatelům s podobným nákupním chováním. Algoritmy pro detekci komunit se dělí na deterministické a nedeterministické. Deterministické vrací pro stejný graf vždy stejný výsledek, zatímco výsledek u nedeterministických může být pro stejný graf mírně odlišný. Mezi deterministické se řadí počítání trojúhelníků, výpočet shlukovacího koeficientu, nebo hledání komponent. Mezi nedeterministické patří například Label Propagation nebo Louvain Modularity. Stejně jako u míry centrality si zde ukážeme pouze pár algoritmů.



Obrázek 10: Graf pro, který počítáme výskyt trojúhelníků

4.3.1 Počítání trojúhelníků

Algoritmus pro každý vrchol určí počet trojúhelníků, kterých je daný vrchol součástí. Trojúhelník je zde definován jako skupina tří navzájem propojených vrcholů. Trojúhelníky nám mohou určit do jaké míry jsou vrcholy v našem grafu propojeny. Čím je graf hustší, tím více trojúhelníků se v něm nachází. Algoritmus je oblíbený při analýze sociálních sítí, kde pomáhá detekovat komunity, nebo zkoumání skupin webových stránek s podobným námětem podle odkazů mezi nimi. Počet trojúhelníků lze využít též pro výpočet shlukovacího koeficientu vrcholu, který určuje pravděpodobnost, s jakou jsou jeho sousedé propojeni (tvoří s ním trojúhelník). Shlukovací koeficient vrcholu u je pak určen vztahem

$$ClusteringCoefficient(u) = \frac{2 * TriangleCount(u)}{deg(u) * (deg(u) - 1)}. \quad (3)$$

Pro ukázkový graf na Obrázku 10 počet trojúhelníků a shlukovací koeficient pro jednotlivé vrcholy zobrazuje tabulka 7. Vidíme, že vrchol A je součástí tří trojúhelníků, které jsou tvořeny vrcholy A-B-C, A-B-D a A-C-D. Stupeň vrcholu je 4. Dosazením do vzorce 3 dostáváme shlukovací koeficient 0.5.

4.3.2 Hledání komponent

Komponentu v grafu tvoří skupina vrcholů, které jsou propojeny a lze se z jednoho vrcholu dostat do dalšího. Najití těchto komponent je užitečné pro pochopení grafové struktury. Algoritmy řešící tento problém jsou rychlé a je možné

Vrchol	A	B	C	D	E	F	G
Triangle Count	3	3	4	4	1	0	0
Clustering Coefficient	0.5	1.0	0.67	0.67	0.33	0.0	0.0

Tabulka 7: Počet trojúhelníků a shlukovací koeficient jednotlivých vrcholů z grafu [10](#)

je využít v grafu, který se často aktualizuje, pro detekci nových vrcholů mezi skupinami. Této znalosti lze využít při různých analýzách. Existuje i varianta, hledající silně souvislé komponenty. Pro graf na Obrázku [10](#) nám algoritmus wcc z knihovny gds vrátí, že všechny vrcholy grafu jsou součástí jedné komponenty.

5 Implementace grafových databází

Existuje spousta implementací grafových databází. Nejznámějšími jsou Neo4j, OrientDB, MemoGraph, TigerGraph, InfiniteGraph...

5.1 Neo4j

Jedná se o nejrozšířenější open-source grafovou databázi. Implementována je v Javě. Nabízí vysoký výkon při práci s grafy. Používá Cypher jako dotazovací jazyk.

5.2 OrientDB

OrientDB je open-source NoSQL databázový systém implementovaný v Javě. Je to multi-model databáze - podporuje grafový, dokumentový, hodnota/klíč a objektový model...

5.3 Dotazovací jazyky v grafových databázích

5.3.1 Gremlin

5.3.2 Cypher

5.3.3 GQL - Graph Query Language

Závěr

Závěr práce v „českém“ jazyce.

Conclusions

Thesis conclusions in “English”.

