

Katedra informatiky
Přírodovědecká fakulta
Univerzita Palackého v Olomouci

BAKALÁŘSKÁ PRÁCE

Grafové databáze – přehled a srovnání



2024

Vedoucí práce:
Mgr. Tomáš Urbanec, Ph.D.

Jan Gaja

Studijní program: Informatika,
Specializace: Obecná informatika

Bibliografické údaje

Autor: Jan Gaja
Název práce: Grafové databáze – přehled a srovnání
Typ práce: bakalářská práce
Pracoviště: Katedra informatiky, Přírodovědecká fakulta, Univerzita Palackého v Olomouci
Rok obhajoby: 2024
Studijní program: Informatika, Specializace: Obecná informatika
Vedoucí práce: Mgr. Tomáš Urbanec, Ph.D.
Počet stran: 58
Přílohy: elektronická data v úložišti katedry informatiky
Jazyk práce: český

Bibliographic info

Author: Jan Gaja
Title: Graph databases – overview and comparison
Thesis type: bachelor thesis
Department: Department of Computer Science, Faculty of Science, Palacký University Olomouc
Year of defense: 2024
Study program: Computer Science, Specialization: General Computer Science
Supervisor: Mgr. Tomáš Urbanec, Ph.D.
Page count: 58
Supplements: electronic data in the storage of department of computer science
Thesis language: Czech

Anotace

Tato práce se zaměřuje na grafové databáze, které představují pokročilý nástroj pro správu a analýzu hustě propojených dat. Prezentuje výhody práce s grafovými daty a jejich aplikace v různých oblastech. Tyto výhody jsou demonstrovány pomocí vybraných implementací grafových databází. Pro experimentální porovnání výkonnosti těchto implementací jsou navrženy specifické dotazy.

Synopsis

This thesis focuses on graph databases, which represent an advanced tool for managing and analyzing densely interconnected data. It presents the advantages of working with graph data and their applications in various fields. These benefits are demonstrated through selected implementations of graph databases. Specific queries are designed for the experimental comparison of the performance of these implementations.

Klíčová slova: grafové databáze; modelování grafových dat; průchod grafem; grafové algoritmy; experimentální porovnání

Keywords: graph databases; graph data modeling; graph traversal; graph algorithms; experimental comparison

Děkuji, děkuji, děkuji.

Místopřísežně prohlašuji, že jsem celou práci včetně příloh vypracoval/a samostatně a za použití pouze zdrojů citovaných v textu práce a uvedených v seznamu literatury.

datum odevzdání práce

podpis autora

Obsah

1	Základní pojmy z teorie grafů	9
2	Grafové databáze	11
2.1	Nativní ukládání a zpracování dat	12
2.2	Datové struktury pro reprezentaci grafu	12
2.2.1	Matice sousednosti	12
2.2.2	Seznam sousedů	13
2.3	Grafové modely	13
2.3.1	Labeled property graph	13
2.3.2	DAG	14
2.3.3	Resource Description Framework	14
2.3.4	Hypergrafy	15
2.4	Systémy OLTP a OLAP	15
2.5	Výhody grafových databází	16
2.6	Nevýhody grafových databází	16
2.7	Implementace grafových databází	17
2.7.1	Neo4j	17
2.7.2	OrientDB	18
2.7.3	ArangoDB	19
2.8	Dotazovací jazyky v grafových databázích	20
2.8.1	Cypher	21
2.8.2	Gremlin	21
2.8.3	AQL	22
3	Modelování grafových dat	22
3.1	Definice problému	25
3.1.1	Co od aplikace očekáváme?	25
3.1.2	Jaké informace budou v databázi uchovávány?	26
3.1.3	Jak spolu tyto informace vzájemně souvisí?	26
3.1.4	Na jaké otázky potřebujeme v aplikaci najít odpověď?	26
3.2	Konceptuální datový model	27
3.2.1	Entity	27
3.2.2	Vztahy	27
3.2.3	Konceptuální model	28
3.3	Logický datový model	28
3.3.1	Vrcholové labely	29
3.3.2	Hranové labely	30
3.3.3	Vlastnosti	31
3.3.4	Logický model	32
3.4	Testování modelu	32
3.4.1	Unit testy	32
3.4.2	Profile a Explain	33
3.4.3	Indexy	34

3.4.4	Denormalizace	34
4	Cestování v grafu	34
4.1	Procházení grafu	35
4.1.1	Prohledávání do šířky	35
4.1.2	Prohledávání do hloubky	36
4.2	Předdefinovaná cesta	36
4.3	Hledání cesty v neohodnoceném grafu	38
4.4	Hledání cesty v ohodnoceném grafu	38
5	Algoritmy	40
5.1	Algoritmy pro hledání cesty v grafu	41
5.1.1	Dijkstra	41
5.1.2	A*	42
5.1.3	Minimální kostra grafu	42
5.1.4	Random walk	43
5.2	Algoritmy pro míru centrality	44
5.2.1	Degree Centrality	44
5.2.2	Closeness Centrality	44
5.2.3	Betweenness Centrality	45
5.2.4	PageRank	45
5.2.5	Použití algoritmů pro míru centrality	45
5.3	Detekce komunit	46
5.3.1	Počítání trojúhelníků a shlukovacího koeficientu	46
5.3.2	Hledání komponent	47
5.3.3	Algoritmus Louvain	47
6	Testování vybraných implementací	48
6.1	Výsledky	49
6.2	Shrnutí	50
6.2.1	OrientDB	50
6.2.2	ArangoDB	52
6.2.3	Neo4j	53
	Závěr	54
	Conclusions	55
	Literatura	56

Seznam obrázků

1	Knowledge graph.	14
2	Hypergraf.	15
3	Rozhodovací strom pro vhodnost použití grafové databáze.	24
4	Konceptuální datový model pro sociální síť pro cestovní nadšence.	28
5	Label vrcholu definuje, do které kategorie vrchol spadá.	29
6	Ukázka více labelů pro jeden vrchol.	30
7	Logický datový model pro sociální síť pro cestovní nadšence.	32
8	Graf vytvořený pomocí zdrojového kódu 2.	33
9	Model grafové databáze pro ukázkové příklady v této kapitole.	35
10	Průchod algoritmu BFS grafem.	36
11	Průchod algoritmu DFS grafem.	37
12	Minimální kostra grafu.	42
13	Příklad grafu, na kterém jsou prováděny algoritmy.	46
14	Distribuce stupně vrcholů.	49
15	Průměrné výsledky dotazů vkládání a mazání.	50
16	Průměrné výsledky dotazů Q1-Q6.	51
17	Průměrné výsledky dotazů Q7 a Q8.	52

Seznam tabulek

1	Tabulka souborů pro aplikaci pro cestovní nadšence.	25
2	Tabulka souborů pro ukázkou hledání cest.	35
3	Výsledná tabulka pro dotaz ve zdrojovém kódu 4.	39
4	Výsledná tabulka pro dotaz ve zdrojovém kódu 5.	39
5	Random walk.	44
6	Výsledky měření centrality.	45
7	Počet trojúhelníků a shlukovací koeficient.	47
8	Algoritmus Louvain.	48
9	Tabulka souborů pro experimentování s databázemi.	49
10	Tabulka použitých dotazů při testování databází.	50

Seznam zdrojových kódů

1	Připojení se k databázi OrientDB v Gremlin Console.	22
2	Unit test.	33
3	Known walk.	38
4	Cesty v neohodnoceném grafu.	39
5	Hledání nejkratší cesty v ohodnoceném grafu.	40

Úvod

Grafové databáze, stejně jako jiné databáze (například relační, NoSQL) představují systém pro uchovávání a zpracovávání dat. Jsou, jak již název napovídá, postaveny na jednom z oborů diskrétní matematiky jménem teorie grafů. Díky této struktuře vykazují skvělé vlastnosti pro aplikace, které ve větší míře pracují se vztahy mezi jednotlivými entitami. V dnešním světě je mnoho problémů, které vyžadují práci s takovými daty. Toho jsou důkazem data z webové stránky [1], která ukazují nejvyšší růst popularity grafových databází v posledním desetiletí ve srovnání s ostatními databázovými modely.

Tato práce má dva cíle. Prvním je představit grafové databáze, jejich silné a slabé stránky, modelování grafových dat a práci s těmito daty. Druhým cílem je otestovat vybrané implementace grafových databází pomocí navržených experimentů.

První kapitola je úvodem do teorie grafů. Obsahuje základní pojmy a definice používané v textu.

Druhá kapitola se věnuje grafovým databázím. Je představeno několik rozdělení grafových databází. Jsou uvedeny jejich výhody a nevýhody. Ukázány různé implementace grafových databází na trhu a dotazovací jazyky pro ně. Převážně pak je pozornost věnována databázím Neo4j, ArangoDB a OrientDB a jim příslušným dotazovacím jazykům Cypher, AQL a Gremlin.

Třetí kapitola popisuje modelování dat v grafových databázích. Postup modelování je ukázán na konkrétním příkladu. Je rozděleno do čtyř fází, které jsou podrobně vysvětleny. Je zde upozorněno na nejčastější chyby, které mohou nastat.

Čtvrtá kapitola pojednává o cestování v grafu. Zabývá se předdefinovanými cestami, které jsou známy a specifikovány v rámci databázového schématu a hledáním cest mezi vrcholy. Všechny části jsou provázeny příklady.

V páté kapitole je nahlédnuto na některé z algoritmů využívaných v grafových databázích. Jsou zde přehledově představeny algoritmy pro hledání cest v grafu, algoritmy pro míru centrality a podívali jsme se na problém detekce komunit.

V šesté kapitole jsou shrnuty výsledky porovnávání třech zvolených grafových databází.

1 Základní pojmy z teorie grafů

V této části jsou uvedeny základní definice a pojmy z teorie grafů používané v textu. Tato kapitola byla napsána pomocí [2], [3], [4] a [5].

Definice 1 (Graf)

Graf G je uspořádaná dvojice $\langle V, E \rangle$, kde V označuje neprázdnou množinu vrcholů a E označuje množinu hran. Každá hrana je určena dvěma vrcholy z V , které spojuje.

V grafu $G = \langle V, E \rangle$ se V nazývá *množina vrcholů* grafu G a označuje se $V(G)$. Podobně E se nazývá *množina hran* grafu G a označuje se $E(G)$.

POZNÁMKA 2 (VRCHOL)

V teorii grafů se pojem vrchol někdy zaměňuje s pojmem uzel. V této práci však budeme používat pojem vrchol.

POZNÁMKA 3 (NEKONEČNÉ GRAFY)

Grafy mohou mít nekonečnou množinu vrcholů. Tyto grafy se nazývají nekonečné. Nekonečné grafy však obecně nelze uchovávat v počítači. V této práci se omezíme na grafy s konečnou množinou vrcholů.

Grafy se dělí na *orientované* a *neorientované*. Hrana v neorientovaném grafu spojující vrcholy u a v se nazývá *neorientovaná* a zapisuje se pomocí množiny obsahující dvojici vrcholů, tedy $\{u, v\}$. Hrana v orientovaném grafu začínající ve vrcholu u a končící ve vrcholu v se nazývá *orientovaná* a pro zápis se používá uspořádaná dvojice, tedy $\langle u, v \rangle$. O hraně začínající i končící ve stejném vrcholu mluvíme jako o *smyčce*. Pro hrany nazýváme *vícenásobné*, pokud existuje mezi dvěma vrcholy hran více, jinak jsou *jednoduché*. Grafu obsahujícímu vícenásobné hrany se říká *multigraf*.

Grafy se nejčastěji znázorňují pomocí kroužků, které představují vrcholy, a úseček mezi nimi, sloužící pro reprezentaci hran. Pokud se jedná o orientovaný graf místo úseček používáme šipky.

Definice 4 (Podgraf)

Podgraf grafu $G = \langle V, E \rangle$ je graf $H = \langle V_1, E_1 \rangle$, kde $V_1 \subseteq V$ a $E_1 \subseteq E$, tak že každá hrana z E_1 má oba vrcholy ve V_1 .

Podgraf $H = \langle V_1, E_1 \rangle$ nazveme *indukovaný*, pokud E_1 obsahuje všechny hrany z E , pro které platí, že mají oba konce v množině V_1 .

Definice 5 (Symetrizace orientovaného grafu)

Symetrizace orientovaného grafu $G = \langle V, E \rangle$ je neorientovaný graf $G' = \langle V, E' \rangle$, pokud pro každou hranu $\{u, v\} \in E'$ platí, že $\langle u, v \rangle \in E$, nebo $\langle v, u \rangle \in E$.

Symetrizaci grafu lze popsat jako proces, ve kterém zapomeneme orientaci hran, odstraníme smyčky a vícenásobné hrany nahradíme jednoduchými a vznikne nám tak neorientovaný graf.

Definice 6 (Ohodnocení hran)

Nechť $G = \langle V, E \rangle$ je graf. Funkce $w : E \rightarrow \mathbb{R}$ se nazývá *ohodnocení hran* grafu G . *Ohodnoceným grafem* nazveme trojici $G = \langle V, E, w \rangle$.

Hodnotu $w(e)$ pro hranu $e \in E$ ohodnoceného grafu $G = \langle V, E, w \rangle$ nazýváme *váha* nebo *ohodnocení hrany* e . Obdobně můžeme definovat *ohodnocení vrcholů* jako funkci $w : V \rightarrow \mathbb{R}$.

POZNÁMKA 7 (OHODNOCENÝ GRAF)

Ohodnoceným grafem v textu budeme vždy myslet graf $G = \langle V, E, w \rangle$, kde přiřazení w je nezáporné ohodnocení hran.

Definice 8 (Sousedství)

Řekneme, že vrcholy $u, v \in V$ v grafu $G = \langle V, E \rangle$ spolu *sousedí*, pokud existuje mezi nimi hrana $e \in E$. Říkáme, že vrcholy u, v jsou *incidentní* s e . *Sousedství* vrcholu $v \in V$ je množina vrcholů $N(v)$ obsahující všechny vrcholy, se kterými vrchol v sousedí.

Definice 9 (Stupeň vrcholu)

Stupněm vrcholu $u \in V$ v grafu $G = \langle V, E \rangle$ se rozumí počet hran s ním incidentních. Značíme jej $\deg(u)$.

Vrcholy se stupněm 1 se v teorii grafů nazývají *koncové* vrcholy, nebo *listy*. Vrcholy se stupněm 0 se nazývají *izolované*. Stupeň vrcholu u lze v orientovaném grafu dále rozdělit podle hran vcházejících a vycházejících na *vstupní stupeň vrcholu* u definovaný jako $\deg_{in}(u) = |\{\langle v, u \rangle | v \in V\}|$ a *výstupní stupeň vrcholu* u definovaný jako $\deg_{out}(u) = |\{\langle u, v \rangle | v \in V\}|$.

Definice 10 (Sled)

Sled v grafu $G = \langle V, E \rangle$ je posloupnost vrcholů a hran tvaru $v_0, e_1, v_1, e_2, \dots, e_n, v_n$, kde vrchol $v_i \in V$ pro všechna $i \in \{0, 1, 2, \dots, n\}$ a hrana $e_j \in E$ vede v grafu G z vrcholu v_{j-1} do vrcholu v_j pro všechna $j \in \{1, 2, 3, \dots, n\}$.

Definice 11 (Cesta)

Cesta je sled, kde se vrcholy ani hrany neopakují.

V neohodnocených grafech má cesta obsahující $n + 1$ vrcholů délku n . Délka cesty v ohodnoceném grafu je rovna součtu ohodnocení hran na cestě.

Definice 12 (Kružnice)

Kružnice je cesta, kde počáteční a koncový vrchol je stejný. U orientovaného grafu používáme pojem *cyklus*.

O grafu $G = \langle V, E \rangle$ řekneme, že je *cyklický*, pokud se v grafu vyskytují kružnice, nebo cykly. Pokud v grafu neexistuje kružnice, graf nazveme *acyklický*.

Definice 13 (Vzdálenost)

Pro vrcholy u, v grafu G definujeme *vzdálenost* vrcholu u a vrcholu v definujeme jako délku cesty z u do v , která je ze všech délek cest z u do v nejmenší. Značíme ji $dist(u, v)$.

Definice 14 (Souvislý graf)

Neorientovaný graf $G = \langle V, E \rangle$ nazýváme *souvislý* pokud pro každé dva vrcholy $u, v \in V$ platí, že existuje cesta z u do v . U orientovaného grafu $H = \langle V_H, E_H \rangle$ rozlišujeme slabou a silnou souvislost. Graf H je *slabě souvislý*, pokud jeho symetrizace je souvislý graf. O grafu H řekneme, že je *silně souvislý*, pokud pro každé dva vrcholy $u, v \in V_H$ platí, že existuje cesta z u do v .

Komponenta grafu G je každý jeho maximální souvislý podgraf.

Definice 15 (Strom)

Strom je souvislý graf $G = \langle V, E \rangle$ neobsahující kružnice.

Množina navzájem nepropojených stromů se nazývá *les*.

Definice 16 (Kořenový strom)

Kořenový strom je dvojice $T = \langle G, r \rangle$, kde $G = \langle V, E \rangle$ je strom a $r \in V$. Vrchol r nazýváme *kořen*.

Opomeňme ohodnocení hran v grafu. *Hloubka vrcholu* v ve stromě $T = \langle G, r \rangle$ je rovna $dist(r, v)$. Speciálně hloubka kořene r je 0. *Výškou kořenového stromu* T rozumíme nejdelší vzdálenost z kořene do některého z vrcholů v T . Vrchol v nazýváme *předchůdce* (rodič) vrcholu u , pokud v kořenovém stromu T existuje cesta z kořene r do u ve tvaru $r \dots, v, e, u$. Vrchol u se pak nazývá *následník* (přímý potomek) v . Pokud vrchol v se vyskytuje na cestě z kořene do u , nazýváme vrchol v *předek* u a vrchol u *potomek* v . Vrcholy mající stejného rodiče označujeme jako *sourozence*. *Listem* nazýváme vrchol, který v kořenovém stromu nemá žádné následníky. Naopak *vnitřní vrchol* je nazýván ten vrchol, který není listem.

2 Grafové databáze

Grafová databáze je specializovaný typ NoSQL databáze určený pro ukládání a dotazování dat, u kterých jsou důležité vztahy mezi objekty. Tento systém rozšiřuje grafový model o operace CRUD. CRUD je zkratka pro čtyři základní

operace – vkládání, čtení, editování a mazání. Díky grafové struktuře navíc lze provádět další specifické operace jako je průchod grafem, díky kterému lze efektivně pracovat se vztahy mezi objekty.

Cílem této části je představit základní vlastnosti grafových databází, jejich výhody v porovnání s jinými typy databází a na závěr je nahlédnuto na některé implementace. Při psaní jsem čerpal z [6], [7], [8] a [9].

2.1 Nativní ukládání a zpracování dat

[10] Grafové databáze můžeme mezi sebou rozlišovat podle zpracování a ukládání dat.

Grafová databáze má *nativní grafové uložště*, pokud umožňuje uchovávání a správu dat v grafové podobě. Tento přístup zefektivňuje práci s databází, neboť uložště je optimalizované přímo pro tento typ dat. Nicméně ne všechny grafové databáze mají grafové uložště. Některé z nich tato data serializují do jiných typů databází. Tento způsob se především opírá o vyspělost a známost jiných technologií.

Druhou vlastností je *index-free adjacency*. Ta nám říká, že v uložšti jsou s každým vrcholem mimo jiné uloženy přímé odkazy (pointery) na sousední vrcholy. Pro přístup k sousedům každého vrcholu tedy není potřeba žádná další datová struktura, nebo globální index. Obdobně to platí pro hrany. S každou hranou máme též uloženy ukazatele na koncové vrcholy, které jsou s danou hranou incidentní. Výsledkem je skvělý výkon při procházení grafem, protože z aktuálního vrcholu se lze dostat na specifický vrchol s konstantní časovou složitostí. Navíc výkon není závislý na velikosti grafu v databázi, nýbrž na množství procházených dat. Toto je obrovská výhoda ve srovnání s relačními databázemi, kde je zpracování požadavku závislé na velikosti spojovaných tabulek. Nevýhodou tohoto přístupu je, že některé dotazy mohou být na výkon nebo paměť mnohem náročnější. Zejména ty, při kterých nedochází k průchodu grafem.

Nativními grafovými databázemi označujeme ty, které s daty manipulují a uchovávají je v grafové podobě. Pracují efektivněji při průchodu grafem. Pro práci s velkým množstvím hustě propojených dat je tato architektura nezbytná. Nenativní grafové databáze jsou bezpečnější volbou pro malé projekty a ne příliš propojená data, neboť obvykle staví na technologiích, které jsou známé.

2.2 Datové struktury pro reprezentaci grafu

Volba reprezentace grafu v databázi má velký vliv na výsledný výkon. Existuje více reprezentací, přičemž každá má své výhody a nevýhody. Dvěmi běžnými reprezentacemi jsou *matice sousednosti* a *seznam sousedů*.

2.2.1 Matice sousednosti

Jedná se o čtvercovou matici o n řádcích a sloupcích, kde n je počet vrcholů. Každý řádek a sloupec je určen pro jeden vrchol. Každá prvek v matici může

nabývat dvou hodnot. Prvek a_u^v na řádku reprezentujícím vrchol u a sloupci reprezentujícím vrchol v platí:

$$a_u^v = \begin{cases} 1 & \text{jestliže } \langle u, v \rangle \in E \\ 0 & \text{jinak.} \end{cases}$$

Pokud je graf neorientovaný, matice sousednosti bude symetrická.

Výhodou tohoto přístupu je rychlé zjišťování zda mezi dvěma vrcholy existuje hrana, přidávání a odebírání hran. Nevýhodou je procházení všech sousedů vrcholu, neboť musíme projít celý řádek matice, tedy n hodnot. Při přidání vrcholu je nutné matici rozšířit. Matice též není vhodná pro reprezentaci „řídkých“ grafů, neboť má kvadratickou prostorovou složitost. Proto na matici sousednosti bývá aplikována komprese.

2.2.2 Seznam sousedů

Pro každý vrchol udržujeme seznam jeho sousedů. Seznam bývá pro rychlé mazání obousměrný. Pokud platí $\langle u, v \rangle \in E$, pak seznam sousedů patřících vrcholu u obsahuje vrchol v .

Výhodou je rychlý přístup k sousedům daného vrcholu. To je žádané při průchodu grafem. Zjištění, zda jsou dva vrcholy propojeny má pak časovou složitost $O(d_{max})$, kde d_{max} je maximální stupeň vrcholu. Prostorová složitost je $O(n+m)$, kde n značí počet vrcholů a m počet hran.

2.3 Grafové modely

[11] Grafové databáze lze rozdělit podle implementace grafového modelu. Všechny tyto modely mají společné, že jejich data mají grafovou strukturu složenou z vrcholů a hran. Dále se však liší různými omezeními a pravidly, kterými je základní definice grafu rozšířena.

2.3.1 Labeled property graph

Tento grafový model bývá označován jako orientovaný multigraf s atributy a labely. Zkráceně jej označujeme LPG. Místo atributu se v terminologii grafových databází ustálil pojem vlastnosti. Vlastnosti jsou obvykle reprezentované pomocí dvojic klíč-hodnota. Tyto vlastnosti mohou být přiřazeny jak vrcholům, tak hranám v jakémkoli množství. Vrcholům a hranám jsou též přiřazeny labely. Pomocí nich je lze seskupovat. Jedná se o koncept, který je nejvíce využíván v grafových databázích. V textu se budeme dále zabývat pouze databázemi implementujícími tento model.

POZNÁMKA 17 (PŘEKLAD)

V práci je použito české slovo „vlastnosti“ přeložené z anglického slova „properties“, se kterým se běžně uživatel setká při práci s grafovou databází. Slovo „label“ je z důvodu znělosti zachováno v původním znění.


2.3.2 DAG

DAG model (anglicky directed acyclic graph) je zkratka pro orientovaný graf bez cyklů. Tento model je vhodný pro plánování úkolů, zpracování dat, nebo systémy pro správu verzí.

2.3.3 Resource Description Framework

Tento model je označován jako RDF. Používá speciální strukturu nazývanou trojice. Tato struktura umožňuje uchovávat věty ve tvaru *Podmět přísudek předmět*. V grafu pak podmět a předmět jsou reprezentovány dvěma vrcholy a přísudek představuje orientovanou hranu mezi nimi. [12] Každý LPG model lze převést na RDF a naopak. Velkou výhodou RDF je jeho jednoduchost v porovnání s LPG.

RDF model je využíván v sémantickém webu pro propojení dat. Dalším příkladem je využití v aplikacích využívajících *znalostní grafy* (anglicky knowledge graphs). Jedním z těchto grafů je Google Knowledge Graph¹. Google jej využívá například ve svém hlasovém ovládání Google Asistenta, nebo od května 2012 data získaná z tohoto grafu vizualizuje v tzv. Knowledge Graph panelu. [13] Knowledge graph pro nizozemského informatika Edsgera Dijkstru zobrazuje obrázek 1.




Obrázek 1: Knowledge graph.

¹<https://blog.google/products/search/introducing-knowledge-graph-things-not/>

2.3.4 Hypergrafy

Hypergraf vznikl zobecněním klasického grafového modelu. Hypergraf obsahuje speciální hrany zvané hyperhrany, které mohou spojovat více vrcholů. Narozdíl od klasické orientované hrany, hyperhrana může mít libovolné množství počátečních a koncových vrcholů. Hypergrafy mohou být užitečné v aplikacích, které zacházejí s vazbami o kardinalitě $M:N$. Vždy je však možné reprezentovat hypergraf jako labeled property graph. I když s použitím více vztahů a zprostředkujících vrcholů. Příklad hypergrafu je ukázán na obrázku 2.



Obrázek 2: Hypergraf.

2.4 Systémy OLTP a OLAP

[14] Grafové databáze dále můžeme rozdělit podle způsobu použití do dvou kategorií:

- *OLTP systémy.* Jsou navrženy pro rychlé a efektivní zpracování velkého množství transakcí. Nejsou vhodné pro analýzu dat. Dotazy většinou prochází pouze poměrně malý podgraf. Grafové databáze jsou obvykle navrhnuty pro použití v OLTP systémech. Hodí se pro aplikace, ve kterých jsou data v reálném čase čtena, přidávána, mazána a modifikována. Nachází využití například v doporučovacích a bankovních systémech, sociálních sítích a při odhalování podvodů.
- *OLAP systémy.* Jsou navrženy pro komplexní analýzu velkého objemu dat. Data se z databáze ve většině případů čtou. Zpracovávají malé množství časově a výpočetně náročných dotazů. Dotazy často operují nad celým grafem. Využívány jsou například v analýze znalostních grafů.

2.5 Výhody grafových databází

V nativních grafových databázích jsou uloženy nejen entity, ale i vztahy mezi entitami. Při dotazování nedochází k výpočtu těchto vztahů, jak tomu je například u relačních databází pomocí klauzule JOIN. To zrychluje zpracování dotazů pracujících se vztahy mezi entitami. Množství uchovávaných dat obecně výkon nezhoršuje, neboť čas pro vyhodnocení dotazu závisí pouze na velikosti podgrafu, kterým procházíme.

Pomocí vrcholů a hran lze často lépe vystihnout dané problémy, než například pomocí tabulek. Grafová struktura popisuje, jak nad daty v rámci aplikace přemýšlíme. Lze tak dosáhnout datových modelů, které jsou srozumitelné i laikům. Navíc ve spoustě případů je dotazování prostřednictvím grafových dotazovacích jazyků přehlednější než dotazy v jiných databázích. To platí především pro dotazy pracující se vztahy mezi entitami.

Většina grafových databází nevynucují definování schématu. Tato vlastnost databází se označuje *schema-less*. Struktura dat se může měnit v závislosti na potřebách aplikace. Přidávání nových vlastností, vrcholů, hran a labelů nenarušuje chod aplikace. To přináší jisté výhody pro vývojáře a budoucí vývoj. Ovšem základní forma dat by měla být známa, abychom mohli s daty pracovat.

Většina grafových databází nabízí grafové algoritmy, které lze aplikovat na uložená data. To rozšiřuje možnosti analýzy propojených dat, které by jinak byly obtížně realizovatelné.

I přes problematické rozdělení grafových dat (sharding) mnoho implementací grafových databází nabízí *horizontální škálování*. To umožňuje rozdělit data mezi více výpočetních strojů. Je spousta technik jak data rozdělit. Například pomocí hashování identifikátorů, nebo pomocí grafových vzorů. Ale volba správné techniky je obtížná. Pro co největší efektivitu databáze by měl být celý graf rozdělen na podgrafy tak, aby mezi jednotlivými podgrafy bylo co nejméně hran, které by je propojovaly. Tyto podgrafy budou uloženy na jednotlivých strojích.

2.6 Nevýhody grafových databází

Grafové databáze jsou mezi ostatními druhy databází poněkud mladé. Narozdíl od relačních databází je všechny mezi sebou nepropojuje jeden standardizovaný dotazovací jazyk. Jeho absence škodí jejich popularitě, neboť pro vývojáře znamená, že pro práci s více grafovými databázemi je nucen používat více různých dotazovacích jazyků, místo specializování se na jeden univerzální. Navíc při změně grafové databáze hrozí, že bude nutné přepsat všechny dotazy do jiného dotazovacího jazyka. Několik grafových databází proto vyžívají pro dotazování speciálně upravený jazyk SQL. Jednou z nich je OrientDB. Tento problém by se však mohl v blízké době zlepšit. Podle dostupných informací se pracuje na normovaném jazyku GQL, což je zkratka pro Graph Query Language².

Grafovým databázím dělají problém dotazy, které operují nad celým grafem.

²<https://www.gqlstandards.org>

Jedná se především o filtrování a agregování. Pokud se v aplikaci soustředíme především na takové typy operací je lepší zvolit jiné databázové technologie.

Jelikož jsou grafové databáze často schema-less, tak může docházet k nekonzistenci ukládaných dat. Ne všechny implementace grafových databází totiž disponují mechanismy, které by v případě potřeby nekonzistenci zabránily. Konzistence dat je tedy často řešena pouze na aplikační úrovni.

2.7 Implementace grafových databází

Existuje spousta implementací grafových databází. Liší se například nativností, dotazovacím jazykem, škálovatelností a podporou ACID transakcí. ACID je zkratka pro čtyři žádané vlastnosti databázových transakcí: atomicita, konzistence, izolovanost a trvalost. Jakou z nich využít pro naši aplikaci je otázka zkoumání funkcionalit jednotlivých implementací. Známymi grafovými databázemi jsou například:

- *Amazon Neptune* – rychlý, spolehlivý, plně řízený a vysoce zabezpečený systém pro hustě propojené grafy. Podporuje jak LPG tak RDF grafový model. Databáze byla představena v roce 2017 společností Amazon. Výhodou je podpora známých dotazovacích jazyků Gremlin, openCypher a SPARQL.[15]
- *TigerGraph* – moderní, nativní grafová databáze pro ukládání LPG grafového modelu. Nabízí vestavěné paralelní výpočty nad grafy.[16]
- *AllegroGraph* – výkonná multi-model open-source databáze. Data mohou být uložena ve formě RDF grafu, vektorů, nebo dokumentů. AllegroGraph je kompatibilní se standardy W3C/ISO a podporuje dotazy prostřednictvím SPARQL a Prologu. Dle [6] nemá nativní grafové zpracování. Předností je kombinování geografických, časových informací a údajů z analýzy sociálních sítí současně v rámci jednoho dotazu. To umožňuje odpovědět na otázky jako: Najdi zda nejvlivnější kamarád Alice (využití analýzy sociálních sítí) v poslední dekádě (časový údaj) provedl platbu kartou 100 kilometrů od Olomouce (geografický údaj).[17]
- *JanusGraph* – jedná se o open-source projekt společnosti The Linux Foundation. Jedná se o odnož grafové databáze Titan. Je založen na Apache TinkerPop a tedy lze klást dotazy prostřednictvím jazyka Gremlin. Kromě online transakčního zpracování (OLTP) podporuje JanusGraph globální grafovou analýzu (OLAP) díky integraci Apache Spark.[18]

Já jsem si vyzkoušel tři implementace, a to *Neo4j*, *OrientDB* a *ArangoDB*.

2.7.1 Neo4j

[19], [20] Databázový systém Neo4j je nejrozšířenější open-source grafovou databází na trhu s největší uživatelskou základnou. Nabízí vysoký výkon při práci s

grafy. Její první verze byla vyvinuta v roce 2002 a vznikla z důvodu nespokojenosti jejich zakladatelů s výkonem relačních databází. Implementována je v Javě. Jedná se o nativní schema-less grafovou databázi. Je využívána světoznámými společnostmi jako jsou Microsoft, eBay, nebo LinkedIn. Klást dotazy můžeme prostřednictvím jazyka Cypher.

Neo4j používá identifikátory s názvem *elementId* pro vrcholy a hrany. Dle dokumentace však není bezpečné používat tyto identifikátory v jednotlivých transakcích a je doporučeno, pokud je jich potřeba, si vytvořit vlastní pomocí *node key constraint* a *relationships key constraint*. Pro rychlý přístup k datům mají záznamy v databázi fixní délku. Jeden vrchol zabírá 15 bytů, jedna hrana 34 bytů. Na disku jsou ukládány ve spojových seznámech.

Neo4j nabízí velké množství produktů. Každý z nich je určen pro jinou cílovou skupinu. Například v této práci je využita aplikace Neo4j Desktop, která slouží pro správu lokálních instancí Neo4j. Verze používané aplikace je 1.5.9. Dalším zajímavým produktem je cloudový databázový servis pojmenovaný Neo4j AuraDB. Vznikl v roce 2019. Je také dostupný v bezplatné verzi, která je však omezená – lze v ní spravovat nejvýše 200 tisíc vrcholů a 400 tisíc hran.

Neo4j má též spoustu rozšiřujících knihoven a nástrojů, které lze do produktů doinstalovat (pokud již nejsou součástí). Například se jedná o nástroj pomáhající při migrování dat z relační databáze do Neo4j, nebo o standardní knihovnu procedur a funkcí. V práci je pak ukázána knihovna s užitečnými grafovými algoritmy.

2.7.2 OrientDB

[21] OrientDB je open-source NoSQL databázový systém implementovaný v Javě. Byl představen v roce 2010 (komerčně 2011). Jedná se o pokročilou multi-model databázi - podporuje grafový, dokumentový, klíč-hodnota a objektový model. Manipulovat s databází můžeme pomocí programovacího jazyka Java, speciálně upraveného SQL a dotazovacího jazyka Gremlin. Uživatelům je pak umožněno interagovat s databází skrze Java API, HTTP REST API, konzolu nebo prostřednictvím grafického uživatelského rozhraní – OrientDB Studio. Pokud OrientDB Server běží lokálně, OrientDB Studio lze najít ve webovém prohlížeči na adrese <http://localhost:2480>. OrientDB je schématicky flexibilní. Umožňuje uchovávat schema-full, schema-less a schema-hybrid data.

Nejmenší jednotkou v databázi je *záznam* (record). Rozlišujeme 4 typy záznamů: Documents, Blobs, Vertices a Edges. Pro každý záznam pak je automaticky vygenerováno ID záznamu, označeno jako RID (Record ID). RID je uchováván ve formátu *#<cluster>:<position>*.

- *<cluster>* označuje identifikátor clusteru, do kterého záznam patří.
- *<position>* udává absolutní pozici záznamu v rámci clusteru.

Tyto záznamy jsou organizovány do *tříd*, jako je tomu v objektově orientovaném programování. Každý záznam pak patří právě do jedné třídy. Třídy mohou

dědit z jiných tříd. Pro vrcholy je výchozí třídou V pro hrany pak třída E. Je silně doporučené vytvářet vlastní definované třídy pro vrcholy a hrany dědící právě z těchto tříd. Každá třída má přidělené vlastní *clustery*. Ty představují fyzický prostor kam OrientDB ukládá data. Vytvoří se při vytvoření třídy. Název clusteru je odvozen z názvu třídy. Pro zlepšení výkonu je vytvořeno tolik clusterů, kolik má CPU na serveru jader. OrientDB též umožňuje tzv. *lightweight* hrany, které zlepšují výkon a snižují nároky na uložení. Tyto hrany však nemohou mít žádné vlastnosti, neboť jsou v databázi reprezentovány pomocí přímých referencí mezi vrcholy.

V práci je využívána bezplatná verze OrientDB Community Edition ve verzi 3.2.23. OrientDB nabízí i placenou verzi Enterprise Edition, která poskytuje výhody jako správu zálohování, migrační nástroje, monitorování systému a CRUD operací v reálném čase a jiné.

2.7.3 ArangoDB

[22] ArangoDB stejně jako předchozí dvě je open-source databáze. Je multi-model databáze. Lze ji použít jako plnohodnotné úložiště dokumentů, grafů a párů klíč-hodnota, full-text vyhledávací engine nebo jakoukoli kombinaci těchto technologií. První verze byla představena společností ArangoDB Inc. v roce 2012. S daty je možno pracovat prostřednictvím jazyka AQL (ArangoDB Query Language). Pokud server provozující ArangoDB běží lokálně je možno interagovat s databází skrze webové rozhraní na adrese 127.0.0.1:8529, nebo prostřednictvím textového rozhraní *arangosh*. Lze též komunikovat prostřednictvím HTTP API, nebo driveru. ArangoDB nabízí též placenou verzi, nabízející například vyšší výkonnost, zabezpečení a škálování grafů. Ačkoli je ArangoDB schema-less, umožňuje vynutit strukturu dokumentů v rámci kolekcí. Toho lze dosáhnout pomocí definování *JSON Schema*³ formátu.

Data jsou ukládána ve známém formátu JSON. Nejmenší jednotkou v databázi je *dokument* – jeden záznam dat. Dokumenty jsou ukládány v binární podobě zvané *VelocityPack*. Dokumenty jsou dále organizovány do *kolekcí*. Kolekce mohou obsahovat libovolné množství dokumentů. Každý dokument patří právě do jedné kolekce. Každý dokument má dále *atributy*, které slouží jako vlastnosti. Každý dokument navíc obsahuje minimálně 3 povinné atributy, nazývané *systémové*, které začínají podtržítkem. Mají datový typ string a všechny jsou určené pouze ke čtení.

- *__key* – nazývá se *dokumentový klíč*. Každý dokument v rámci kolekce má hodnotu tohoto atributu unikátní. Dokumentový klíč lze specifikovat při vytváření dokumentu. Pak již nelze změnit. Pokud není specifikován, je atributu přiřazena hodnota automaticky.
- *__id* – nazývá se *dokumentový identifikátor*. Identifikuje dokument v rámci databáze. Je ve formě *<název-kolekce>/<klíč-dokumentu>*.

³<https://json-schema.org/>

- `__rev` – nazývá se *dokumentová revize*. Hodnota atributu je automaticky obdržena serverem.

Hrany v databázi jsou uloženy ve speciálních dokumentech a kolekcích, nazvané *hranové*. A mají další dva systémové atributy.

- `__from` – hodnota atributu je rovna dokumentovému identifikátoru počátečního vrcholu.
- `__to` – hodnota atributu je rovna dokumentovému identifikátoru koncového vrcholu.

Další atributy jsou uživatelsky definovatelné.

Databáze nepoužívá přímo index-free adjacency. Místo toho používá tzv. hybridní index. Jeho výhoda se dle ArangoDB projevuje u větších grafů, které celé nejdou načíst do paměti. Hybridní index kombinuje výhody spojového seznamu a hashovací tabulky, přičemž dosahuje časové složitosti $O(k)$ v případě procházení grafu, kde k je stupeň vrcholu, a $O(1)$ při editování a mazání hran. Oproti tomu index-free adjacency má i v případě mazání a editování v nejhorším případě časovou složitost $O(k)$, což se negativně projevuje převážně u superuzlů. [23]

2.8 Dotazovací jazyky v grafových databázích

Pomocí dotazovacích jazyků lze formulovat dotazy, které lze klást na databázi. Pomocí nich lze definovat *grafové vzory*. Ty popisují, jakým způsobem grafem procházíme. Na základě specifikovaných vzorů a mechanismu zvaném pattern matching následně můžeme dostat odpovědi na dotazy.

Jak již bylo zmíněno pro grafové databáze zatím neexistuje jeden standardní jazyk. Lze narazit na jazyky vyvinuté specificky pro konkrétní systém. Příkladem může být jazyk *Cypher* vyvíjený společností Neo4j nebo *AQL* využívaný v databázi ArangoDB. Na druhou stranu jsou zde jazyky, jakým je například *Gremlin*, které lze použít ve více systémech zacházejících s grafy – například v OrientDB. Následující seznam obsahuje další známé dotazovací jazyky.

- *SPARQL* – je standardizovaný dotazovací jazyk využívaný v grafových databázích implementujících RDF model. [24]
- *PGQL* – je jednou z komponent datové databáze společnosti Oracle, který je rozšířením SQL. Podporuje jak LPG, tak RDF grafový model. Implementuje vestavěné grafové algoritmy. [25]
- *GSQL* – procedurální jazyk používaný v databázi TigerGraph podobný SQL. Slibuje vysoký výkon díky vestavěnému paralelismu. [26]
- *GraphQL* – jedná se o dotazovací jazyk pro API, který není závislý na konkrétní implementaci. Za jeho vývojem stojí Facebook. Je považován za přímého konkurenta REST API. [27]

2.8.1 Cypher

[19], [20] Cypher je inspirovaný známým jazykem SQL z relačních databází. Důkazem může být použití několika stejnojmenných klíčových slov, jako je WHERE, LIMIT, ORDER BY apod. Navíc v obou případech se jedná o deklarativní dotazovací jazyky. Myšlenkou deklarativních jazyků je definování, jaká data chceme z databáze dostat, místo definování jak je dostat.

Cypher je unikátní v tom, že při definování grafových vzorů využívá kulaté závorky pro vrcholy a hranaté pro hrany, čímž docílí lepší přehlednosti v dotazu. Základní syntaxe pro průchod grafem z vrcholu *vrchol1* na vrchol *vrchol2*, přes hranu HRANA, která je spojuje, je ve formátu

$$(vrchol1)-[:HRANA]->(vrchol2).$$

Obdobně jako v SQL je základní dotaz v Cypheru složen ze tří částí. První je povinná a začíná klíčovým slovem MATCH. Definujeme v ní grafový vzor. Druhá část, nepovinná, začíná klíčovým slovem WHERE. V ní filtrujeme vybrané elementy z první části dotazu pomocí vlastností, nebo dalších grafových vzorů. Poslední povinná část začíná klíčovým slovem RETURN. Určuje, co je po provedení dotazu vráceno. Na výsledky lze aplikovat další operace, jakými jsou například agregování, limitování, nebo seřazování.

Pro úsporu paměti implementuje vždy, když je to možné, *líné vyhodnocování dotazů* (anglicky lazy evaluation). Tedy u většiny operátorů nečekáme na všechny výsledky aplikace daného operátoru, ale hned po jejich získání na ně aplikujeme další nadřazený operátor. Výpočet podřazeného operátoru tedy obecně nemusí skončit dříve, než na výsledky začneme aplikovat nadřazený operátor. Tím nedochází k zatěžování paměti mezivýsledky výpočtu. Nicméně ne všechny dotazy lze vyhodnocovat líně. Pro operace jako je třídění, nebo agregování je nutné použít *striktní vyhodnocování dotazů* (anglicky eager evaluation). S výsledky pak nadřazený operátor manipuluje až po úplném skončení výpočtu.

2.8.2 Gremlin

[28], [29], [21] Gremlin je dotazovací jazyk pro procházení grafů, který je součástí grafového výpočetního frameworku Apache TinkerPop⁴. Gremlin lze použít pro všechna grafová uložiska, která tento framework podporují. Je to imperativní jazyk s nějakými deklarativními prvky. Podobně jako Cypher ve většině případů vyhodnocuje dotazy líným způsobem.

Apache TinkerPop mimo jiné obsahuje také Gremlin Console, což je textové REPL (Read-Eval-Print Loop) rozhraní pro práci s lokálními, či vzdálenými grafy. Je založená na Groovy konzoli. Groovy je programovací jazyk, který je označován jako nadmnožina Javy. Co funguje v Javě funguje i v Groovy. V konzoli tedy můžeme používat validní kód napsaný v tomto jazyce. Díky tomu lze

⁴<http://tinkerpop.apache.org/>

například uložit do proměnné určitý vrchol a na něj se pak přes danou proměnnou odkazovat. Konzole je široce rozšiřitelná pomocí různých pluginů.

Pro napojení na databázi OrientDB budeme potřebovat plugin `tinkerpop.orientdb`. Když je tento plugin aktivovaný, lze v konzoli vytvořit novou instanci `OrientGraph`. Uložíme ji do proměnné `graph`. Při vytváření je nutné specifikovat URL pro připojení k databázi. Připojit se můžeme k lokální databázi, vzdáleně k databázovému serveru, nebo k jednorázové databázi v paměti. Může být též potřeba zadat přihlašovací údaje. Než začneme psát dotazy pomocí Gremlinu musíme ještě vytvořit instanci zdrojového objektu pro procházení grafu zavoláním metody `traversal()` na hodnotu v proměnné `graph`. Ta se ukládá ve většině případů do proměnné `g`. Celý postup je uveden ve zdrojovém kódu 1.

```
1 //OrientDb database connector
2 graph = OrientGraph.open(url, user, password);
3
4 //establishing a graph traversal source object
5 g = graph.traversal();
```

Zdrojový kód 1: Připojení se k databázi OrientDB v Gremlin Console.

2.8.3 AQL

[22] Jedná se převážně o deklarativní dotazovací jazyk používaný v databázi ArangoDB. Snaží se být nezávislý na klientovi (client-independent). To znamená, že jazyk a syntaxe není závislá na programovacím jazyku, který klient využívá. Obdobně jako velká část grafových dotazovacích jazyků je ovlivněný jazykem SQL. Jazyk je jednotný pro všechny databázové modely. AQL je čistě DML (Data Manipulation Language) jazyk. Tedy umí číst a manipulovat s daty v kolekcích. Neumí vytvářet a odstraňovat databáze, kolekce a indexy.

Každý dotaz v AQL musí buď vrátet výsledky pomocí klíčového slova `RETURN`, nebo provádět operaci, která modifikuje data. Je podporován pouze jeden dotaz v rámci jednoho dotazovacího řetězce. Není možné provést výpočet více oddělených dotazů pro jedno zavolání. Dotaz je opět vyhodnocován líně, pokud se v něm neobjevují poddotazy, ty jsou ve výrazech vyhodnocovány předem, příkladem je ternární operátor. Dotazy lze klást prostřednictvím webového rozhraní, nebo konzole *arangosh*. V práci se dotazy kladly pouze prostřednictvím první zmíněné možnosti.

3 Modelování grafových dat

Tato kapitola byla napsána s využitím knih [30], [6], [31]. Dále byly využity tyto zdroje [9], [32] a [20].

Při *modelování grafových dat* se snažíme reprezentovat náš problém grafem. Jedná se o proces, ve kterém rozpoznáváme jednotlivé entity a vztahy mezi nimi, které v problému vystupují. Problém pak popisujeme jako graf skládající se z vrcholů a hran pomocí vlastností a labelů. Podoba výsledného modelu závisí na potřebách vyvíjené aplikace a otázkách, které mají podobu dotazů, které budou na databázi kladeny.

Dodržení základních principů modelování dat je důležité pro výslednou efektivitu. Pro správné fungování je proto dobré věnovat dostatečné množství času. Když je graf přizpůsoben dotazům, dokáže velmi rychle nalézt potřebnou odpověď. Naopak špatně zvolený model grafu může ve výsledku aplikaci ublížit a být překážkou. Například tím, že zpracování dotazu bude trvat déle než u optimalizovaného modelu. Další důležitou věcí, na kterou je potřeba myslet, je budoucnost vyvíjené aplikace. Model by měl být připravený na možné změny, které po aplikaci budou její koncoví uživatelé požadovat.


Je potřeba také podotknout, že ne všechna data jsou vhodná pro uchovávání v grafové podobě. Rozhodnutí, zda pro naše účely je grafová databáze dobrým řešením, je ve spoustě případů náročné. Existují různé typy databází (například relační, dokumentové, nebo klíč-hodnota) a každá má své silné a slabé stránky a je potřeba si dobře promyslet, kterou zvolit. Grafové databáze jsou výhodné pro aplikace, které mají vztahy mezi entitami na prvním místě. Tato vlastnost by měla být odrazovým můstkem při rozhodování, zda použít, či nepoužít grafovou databázi. Lze dohledat spoustu „návodů“ pomáhajících s touto volbou. Jeden z nich je ukázán na obrázku 3. Zobrazuje rozhodovací strom převzatý z knihy [30].

Pokud se pro požití grafové databáze rozhodneme, můžeme přistoupit k modelování dat. V této kapitole se tedy zaměříme na návrh grafového modelu. Zkusíme si to na příkladu sociální platformy pro nadšence cestování. Sociální sítě jsou totiž jedním z případů, kdy použití grafových databází pro ukládání dat dává smysl. Tato aplikace tedy bude umožňovat cestovatelům se propojit s ostatními. Dále bude zaznamenávat jejich výlety do různých destinací, hodnocení těchto cest, cestovatelské aktivity, které destinace nabízí a které se mohou uživatelům aplikace líbit. Na základě svých přátel a hodnocení cest do destinací aplikace dokáže uživateli doporučit jiné destinace, které dosud nenavštívil. Naše aplikace se tedy bude dotýkat i dalšího případu užití grafových databází, a to systémů pro doporučování, které jsou v praxi hojně využívány.

Pro vyzkoušení dotazů můžeme využít csv souborů, obsahujících vygenerovaná data pro naši aplikaci. Seznam všech souborů, rozdělený na entity a vztahy mezi nimi a počet řádků (včetně hlavičky) jednotlivých souborů lze vyčíst z tabulky 1.

Postup modelování se dá rozdělit do čtyř fází:

1. Definice problému,
2. Konceptuální datový model,
3. Logický datový model a



Obrázek 3: Rozhodovací strom pro vhodnost použití grafové databáze.

Tabulka 1: Tabulka souborů pro aplikaci pro cestovní nadšence.

Typ	Název souboru	Počet	Informace o souboru
Entity	activities.csv	48	Aktivity, které mohou destinace nabízet.
	countries.csv	57	Státy, v kterých se vyskytují jednotlivé destinace.
	destinations.csv	203	Destinace, které mohou uživatelé navštívit.
	journeys.csv	296	Cesty, v rámci kterých uživatelé navštěvují destinace.
	ratings.csv	640	Hodnocení jednotlivých cest uživateli.
	users.csv	300	Uživatelé sociální sítě Travel Enthusiast Network.
Vztahy	follows.csv	6091	Uživatel sleduje uživatele.
	is_within.csv	203	Destinace je ve státu.
	led_to.csv	1496	Cesta vedla do destinace.
	likes.csv	1460	Uživatel má rád cestovní aktivitu.
	offers.csv	2028	Destinace nabízí cestovní aktivitu.
	participated.csv	1643	Uživatel se zúčastnil cesty.
	wrote_about.csv	640 + 640	Uživatel napsal recenzi o cestě.

4. Testování modelu.

V následujících částech se na jednotlivé fáze podíváme detailněji.

3.1 Definice problému

V první fázi bychom měli zvážit co všechno by měla aplikace umět. Výsledkem by měl být její, co nejpřesnější, slovní popis. Pomoci nám může odpovědět na těchto pár otázek, převzaté z knihy [30].

3.1.1 Co od aplikace očekáváme?

Aplikace je sociální sítí, a proto by měla jednotlivým uživatelům umožňovat se propojit s ostatními uživateli aplikace. To je umožněno pomocí relace sledování. Uživatelům by pak na základě jimi sledovaných uživatelů, oblíbených aktivit a hodnocení destinací měly přicházet tipy na výlet. Aplikace by měla umožnit zazanamenat, že někteří uživatelé podnikli cestu společně. Uživatelé budou moci v rámci jedné cesty navštívit více destinací.

3.1.2 Jaké informace budou v databázi uchovávány?

- Potřebné údaje o uživateli – jejich jméno, příjmení, unikátní identifikátor, oblíbené cestovatelské aktivity.
- Informace o cestách, které uživatel podnikl – název cesty, časové údaje, jejich recenze.
- Informace o destinacích – lokace, název, nabízené cestovatelské aktivity.

V reálném scénáři by projekt pravděpodobně zahrnoval mnoho dalších informací, ale pro tuto ukázkovou aplikaci to ponecháme omezené. Pro zjednodušení se vyhneme přesným souřadnicovým informacím a vystačíme si s informací v rámci jakého státu se daná destinace nachází. Dále uživatelům aplikace bude dovolovat psát hodnocení na dané cesty, nikoliv na destinace, které v rámci cesty podnikl. Uživatelé cestující spolu se budou účastnit stejné cesty do destinací.

Aplikace by tedy měla zacházet s pojmy jako je uživatel, destinace, stát, cesta, recenze a cestovatelská aktivita.

3.1.3 Jak spolu tyto informace vzájemně souvisí?

Následující seznam ukazuje, jakým způsobem jsou odpovědi na předchozí otázku mezi sebou propojeny.

- Uživatel **sleduje** jiného uživatele.
- Uživatel **se zúčastnil** cesty **vedoucí do** destinace.
- Uživateli se **líbí** cestovatelská aktivita.
- Uživatel **napsal** recenzi **o** cestě.
- Destinace **nabízí** cestovatelskou aktivitu.
- Destinace **je ve** státě.

3.1.4 Na jaké otázky potřebujeme v aplikaci najít odpověď?

- Jaké všechny uživatele sleduji? A koho sledují oni? Které uživatele nesleduji, ale sledují je uživatelé, které sleduji?
- Najdi 3 nejlépe hodnocené destinace, které jsem nenavštívil, nabízející konkrétní cestovní aktivity?
- Které destinace navštívil uživatel X? Kolikrát je navštívil?
- Najdi mi všechny uživatele v rámci skupiny, s kterou cestuje uživatel X do destinace Y.

- Najdi destinace nabízející některé z cestovatelských aktivit, které se uživatelé líbí. Seřaď je na základě hodnocení.
- Pro konkrétní destinaci vrať měsíc v roce v kterém je nejlépe hodnocená.
- Najdi uživatele, jejichž jméno nebo příjmení obsahuje řetězec XYZ.

Tyto otázky po vytvoření modelu přeložíme pomocí dotazovacího jazyka na dotazy.

3.2 Konceptuální datový model

V této fázi vyvineme konceptuální model. Výstupem by měl být přehledný diagram popisující typy dat v naší aplikaci. Vyvarujeme se v něm pro nevyvojáře zbytečným detailům a zaměříme se pouze na to, jak data různých typů v rámci vyvíjené aplikace spolu souvisí. Tento proces vyžaduje identifikování a seskupení všech entit a vztahů, které se v naší aplikaci vyskytují. Je možné, že model navrhne špatně a budeme jej muset předělat.

Při vyvíjení datového modelu vývojáři často kreslí na tabuli, jak jsou data v rámci projektu propojena s dalšími. Proto se konceptuální model v některých literaturách nazývá *whiteboard model*.

3.2.1 Entity

Entity většinou představují objekty, jakými jsou například *Uživatel*, *Účet*, nebo *Město*, které jsou v databázi uloženy a propojeny vzájemnými vztahy.

Jedním z osvědčených postupů, jak v našich poznámkách z předchozí fáze identifikovat entity, je dívat se po podstatných jménech. Pokud se budeme řídit tohoto postupu, tak z věty „Uživatelé se líbí cestovatelská aktivita.“ získáme dvě entity, a to *Uživatel* a *Cestovatelská aktivita*. Avšak ne všechna podstatná jména jsou nutně entity. Příkladem může být podstatné jméno „příjmení“. Příjmení v naší aplikaci chápeme jako součást uživatele. Díky ní budeme moci rozlišovat jednotlivé uživatele. V této fázi se jedná o nepodstatný detail.

V naší aplikaci můžeme dohromady rozpoznat 6 různých entit: *Uživatel*, *Cesta*, *Destinace*, *Aktivita*, *Stát* a *Recenze*.

3.2.2 Vztahy


Nyní následuje propojení entit pomocí vztahů. Podobně jako u entit, vztahy získáme zaměřením se na slovesa vyskytujících se v popisu problému. Zde bychom však měli být velmi opatrní. Ve slovese se může ukrývat podstatné jméno. Zanedbáním tohoto faktu bychom mohli přijít o důležitou entitu v naší aplikaci. To by mohlo nést v budoucnosti následky při rozšiřování funkcionality aplikace a mohlo by to vést k migrování databáze. Dobrým příkladem je sloveso „recenzovat“. Pokud bychom při modelování zvolili větu „Uživatel recenzoval X.“ místo „Uživatel napsal recenzi o X.“, tak bychom mohli v budoucím vývoji aplikace

narazit na problém, že nemáme entitu představující recenzi, na kterou bychom se mohli odkazovat. Snadno si jde domyslet komentování nebo jiný způsob reagování na recenze. Podobně, pokud bychom v naší aplikaci upřednostnili větu „Uživatel navštívil destinaci.“ před větou „Uživatel podnikl cestu do destinace.“, uživatel by pak nemohl danou cestu hodnotit tak, jak to máme v popisu naší aplikace.

Pokud váháme, zda určitý typ dat má tvořit entitu nebo relaci v našem modelu, je obecně doporučeno se rozhodovat podle toho, zda některý dotaz na databázi dostane na vstupu informaci ve formě tohoto typu dat. Pokud ano, tato data bychom měli reprezentovat jako entitu. Například lze takto odvodit, že slovo Uživatel musí být entita, protože je vstupem (proměnnou) v dotazu odpovídajícím na otázku „Které destinace navštívil uživatel X?“.

3.2.3 Konceptuální model

Po důkladném rozmýšlení má naše tabule stejný obsah, jako na obrázku 4.




Obrázek 4: Konceptuální datový model pro sociální síť pro cestovní nadšence.

3.3 Logický datový model

V této fázi definujeme základní schéma, které bude určovat podobu našich dat v databázi. Stačí v konceptuálním modelu z minulé fáze převést entity na vrcholy, vztahy na hrany a přiřadit jim příslušný label a vlastnosti. Výstupem tedy bude návrh schématu ve formě grafu, který bude mnohem detailnější než konceptuální model. Ten se nazývá *logický datový model*. Bude se zabývat detaily, kterými se zabývají vývojáři. Poté již můžeme do naší databáze vložit zkušební data a vyzkoušet dotazy, které budou odpovídat na naše otázky načrtnuté v první části modelování dat.

3.3.1 Vrcholové labely

Podstatnou část práce již máme za sebou, neboť můžeme využít dobře navrženého konceptuálního modelu a namapovat naše entity na vrcholové labely. Label vrcholu u určuje, do které skupiny, nebo kategorie vrcholů vrchol u patří. Všechny vrcholy se stejným labelem pak spadají do stejné kategorie. Label pak můžeme používat v dotazech na databázi a pracovat tak s různými skupinami vrcholů a dosáhnout tak lepšího výkonu při dotazování. Pro lepší pochopení je zde obrázek 5.




Obrázek 5: Label vrcholu definuje, do které kategorie vrchol spadá.

Labely vrcholů by měly být výstižné, krátké a přesné. Musíme mít na paměti budoucí rozšířitelnost aplikace a fakt, že s databází může pracovat jiný vývojář. Při přiřazování labelu je dobré myslet na jeho co největší obecnost, protože v budoucnu bychom mohli potřebovat reprezentovat jiný podobný koncept a tedy je užitečné volit co nejobecnější label.

Povolený počet labelů pro jeden vrchol se u různých grafových databází liší. Jednou z možností je každému vrcholu přiřadit právě jeden label. To je například přístup ArangoDB databáze. Často se ale také hodí mít labelů více a pomocí nich umět vyjádřit dědičnost. Vrcholy pak spadají do více skupin vrcholů naráz. Tento přístup podporuje databáze Neo4j. Příkladem může být systém pro správu zaměstnanců a klientů ve firmě. Kromě vrcholových labelů *Zaměstnanec* a *Klient* použijeme také label *Osoba*. Neboť zaměstnanec, reprezentovaný vrcholem v databázi, jistě sdílí s klientem informace jako je jméno, datum narození a podobně, ale může mít nějaké dodatečné informace, jako je například plat, nebo identifikační číslo zaměstnance. Nyní jednoduše můžeme vybrat data týkající se pouze klientů, ale zároveň můžeme požádat databázi o informaci o všech lidech spravovaných v databázi. Příklad přiřazení více labelů jednomu vrcholu je znázorněn na obrázku 6.

Častou chybou při navrhování labelů je nekonzistentní pojmenovovací konvence. Proto je dobré si nyní stanovit pojmenovovací konvenci, kterou se budeme



Obrázek 6: Ukázka více labelů pro jeden vrchol.

řídit.

POZNÁMKA 18 (KONVENCE POJMENOVÁNÍ)

V našem příkladu je zvolena konvence doporučená v dokumentaci databáze Neo4j a tedy pro labely vrcholů budeme používat *UpperCamelCase* notaci, pro labely hran *SCREAMING_SNAKE_CASE* notaci s použitím podtržítka pro oddělení slov a pro vlastnosti camelCase notaci.

3.3.2 Hranové labely

Při hledání hran opět využijeme připraveného konceptuálního modelu. Podobně jako u vrcholů se zamyslíme nad labely hran, které by opět měly být obecné a výstižné. Navíc bychom se měli držet jedné dobré zásady. Přečtením labelů počátečního vrcholu, hrany z něj vycházející a cílového vrcholu do nějž hrana vstupuje by nám mělo dávat vcelku smysluplnou větu. Příkladem by mohla být věta „Uživatel napsal hodnocení.“, která vznikla spojením vrcholového labelu *Uživatel*, hranového labelu *napsal* a labelu cílového vrcholu *Hodnocení*. Ve většině případů mají věty tvar podle následující posloupnosti větných členů – podmět-přísudek-předmět. Hrany mají obecně jeden label, někdy označovaný jako *typ* hrany.

Vytvořené věty nám určují i orientaci hran. Opačná orientace hrany by ve většině případů způsobila, že přečtením daných labelů bychom dostali nesmyslnou větu. Pokud bychom tedy požadovali opačnou orientaci hran, museli bychom přistoupit ke změně labelu hrany. Orientace hrany by měla reflektovat to, jak přirozeným způsobem přemýšlíme o datech v naší doméně.

Nyní zbývá ještě určit *jedinečnost* hran. Jedinečnost lze definovat jako počet hran se stejným labelem mezi dvěma vrcholy. Tyto vrcholy mohou a nemusí mít stejný label. Jedinečnost hran se dělí na dva typy: *jednoduchá* a *mnohonásobná*. Jednoduchá jedinečnost znamená, že mezi dvěma vrcholy existuje nejvýše jedna hrana se stejným labelem. Vícenásobná povoluje takových hran více. Na jednoduchou jedinečnost hrany s konkrétním hranovým labelem lze též nahlížet tak, že skupina sousedních vrcholů, do kterých se dostaneme přes hrany s tímto labelem,

neobsahuje více instancí jednoho vrcholu – tedy tvoří množinu vrcholů. Zatímco u mnohonásobné jedinečnosti dostaneme takto kolekci sousedních vrcholů, kde se vrcholy mohou opakovat.

Všechny hrany v naší aplikaci, až na hrany mezi vrcholy s labelem *Cesta* a *Destinace* budou mít jedinečnost jednoduchou. Neboť například vztah mezi daným uživatelem a cestovatelskou aktivitou buď je, nebo není a to lze vyjádřit pomocí existence jedné hrany mezi těmito dvěma vrcholy. Totéž platí pro ostatní hranové labely, až na hranu s labelem *VEDLA*. Jistě totiž může existovat situace, kdy v rámci cesty uživatel do dané destinace zavítá vícekrát a s touto možností by náš model měl také počítat. Tedy tato hrana bude mít vícenásobnou jedinečnost. Tyto hrany pak od sebe rozlišíme pomocí vlastností, které budou určovat období, kdy se daný uživatel v dané destinaci nacházel. Hrany s mnohonásobnou jedinečností bychom měli rozlišovat pomocí vlastností, aby byly unikátní.

Zvolení správné jedinečnosti hran je klíčové pro správné chování databáze. Pokud zvolíme jednoduchou jedinečnost tam, kde by měla být vícenásobná, databáze může vrátit méně dat než očekáváme. Naopak, vícenásobná jedinečnost hran tam, kde by měla být jednoduchá, může vést k duplikativním datům a sníženému výkonu dotazů. Každá hrana se stejným labelem mezi dvěma vrcholy zvyšuje čas výpočtu a komplikuje průchod grafem. U některých implementací grafových databází, jako například DataStax Graph, lze tuto jedinečnost vynutit jako součást při definování schématu. U implementací bez schématického přístupu, jako je Neo4j, tuto jedinečnost lze ošetřit pouze v rámci aplikace.

3.3.3 Vlastnosti


Poslední zastávkou při konstruování logického modelu jsou vlastnosti. Základní prvky grafu máme, ale chybí nám způsob jak rozlišit jednotlivé vrcholy (a někdy i hrany) se stejným labelem. K tomu nám slouží vlastnosti. V grafových databázích mohou mít vlastnosti jak hrany tak vrcholy, neboť hrany jsou pro nás stejně významné jak vrcholy.

Vlastnosti v grafové databázi jsou páry klíč-hodnota a popisují konkrétní atributy hrany, či vrcholu. Hodnota vlastnosti může být různého datového typu, například řetězec, číslo, pravdivostní hodnota nebo datový typ pro uchování datumu a času. Někdy též může být hodnota typu pole nebo seznam. Jednou z vlastností bývá námi definovaný unikátní identifikátor každého vrcholu, díky kterému přistupujeme ke konkrétním vrcholům.

K dokončení logického modelu nám tedy zbývá najít a správně přiřadit potřebné vlastnosti konkrétním vrcholovým a hranovým labelům, rozumně je pojmenovat a určit jejich datový typ. K jejich nalezení nám opět mohou pomoci otázky, které chceme aby nám databáze zodpověděla. Z nich můžeme jednotlivé vlastnosti identifikovat a přiřadit.

3.3.4 Logický model

Naše výsledné grafové schéma popisuje obrázek 7. Vrcholové labely jsou uvedeny v kroužcích. Hranové labely jsou vepsány do šipek. Vlastnosti vrcholů a hran jsou zobrazeny v obdélnících nacházejících se u vrcholů a na hranách.



Obrázek 7: Logický datový model pro sociální síť pro cestovní nadšence.

3.4 Testování modelu

Testování našeho grafového modelu spočívá ve vyzkoušení, zda se chová dle našeho očekávání (databáze vrací očekávané výsledky) a dotazování není moc pomalé ani pro velké množství dat. K testování lze využít široké škály nástrojů, které dotazovací jazyky a databáze nabízejí.

3.4.1 Unit testy


Při testování správnosti dotazů je vhodné použít tzv. *unit testy*. Tedy vytvoříme si pro každý dotaz malé množství testovacích dat (například kolem 10 vrcholů, tak abychom z něj pouhým okem vyčetli správnou odpověď), kterými otestujeme správnost odpovědí z databáze. Příkladem unit testu je zdrojový kód 2. Tento kód vloží do databáze data, která tvoří graf znázorněný na obrázku 8. Následně zkontroluje dotaz hledající všechny uživatele, které mají od uživatele s vlastností `userId` rovnou 1 vzdálenost rovnou 2. Vidíme, že po spuštění testu databáze by měla vrátit uživatele s identifikátory 4 a 5. Následně po sobě uklidíme. Smažeme testovací data.

```

1 // Vytvoření testovacích dat
2 CREATE (u1:User {userId: 1, firstName: "John", lastName: "Doe"})
3 CREATE (u2:User {userId: 2, firstName: "Lisa", lastName: "Fog"})
4 CREATE (u3:User {userId: 3, firstName: "Bob", lastName: "John"})
5 CREATE (u4:User {userId: 4, firstName: "Jane", lastName: "Doe"})
6 CREATE (u5:User {userId: 5, firstName: "Paul", lastName: "Bae"})
7
8 CREATE (u1)-[:FOLLOWS]->(u2)
9 CREATE (u2)-[:FOLLOWS]->(u3)
10 CREATE (u1)-[:FOLLOWS]->(u3)
11 CREATE (u2)-[:FOLLOWS]->(u4)
12 CREATE (u3)-[:FOLLOWS]->(u5)
13
14 // Spuštění testu
15 MATCH (u:User {userId: 1})-[:FOLLOWS]->(u2)-[:FOLLOWS]->(u3)
16 WHERE NOT EXISTS((u)-[:FOLLOWS]->(u3)) AND u3 <> u
17 RETURN u3;
18
19 // Smazání testovacích dat
20 MATCH (u:User) WHERE u.userId IN [1, 2, 3, 4, 5]
21 DETACH DELETE u;

```

Zdrojový kód 2: Unit test.



Obrázek 8: Graf vytvořený pomocí zdrojového kódu 2.

3.4.2 Profile a Explain

Pokud čelíme pomalému vykonávání některých dotazů, můžeme použít dva nástroje pro diagnostiku problémů.

První z nich se nazývá *explain* a slouží pro vysvětlení jak se bude průchod grafem vyvíjet na základě našeho dotazu. Používá se v situacích, kdy chceme

zjistit chování průchodu grafem, ale nechceme jej vykonat. Výsledkem je optimalizovaný exekuční plán daného dotazu, který by byl vykonán na datech.

Druhému říkáme *profile* a podle dodaného dotazu profiluje, co průchod grafem udělal. Profile je hojně používaným nástrojem pro analýzu dotazů, neboť dotazy jsou často pomalé pouze pro několik vrcholů – například těch, které mají vysoký stupeň. Toho lze využít k porovnání chování rychlých a pomalých vykonání dotazu. Získané informace pak využijeme k optimalizování našich dotazů.

3.4.3 Indexy

Pro efektivní hledání dat v rámci grafu lze použít *indexy*. Toho lze využít pro vylepšení dotazů, neboť díky nim můžeme zrychlit průchod grafem, přístup ke konkrétním datům a další operace pracující s daty. Indexy vytvoří redundantní kopii vybraných dat v databázi podle zadaných kritérií. Jsou výhodné pro data, které jsou častým terčem hledání. Nejčastěji se jedná o vlastnosti, které často vystupují ve filtrování dat v dotazu, nebo identifikátory vrcholů. Dále se využívají pro vlastnosti, na kterých jsou prováděny různé operace s řetězci. Příkladem je hledání slov začínající, končící, nebo obsahující určitý podřetězec.

Implementace jako je TinkerGraph poskytuje pouze globální indexy jedné hodnoty. Oproti tomu databáze jako Neo4j nabízí celou škálu různých typů indexů. Indexy také však mají nevýhody. Zvyšují nároky na úložný prostor a mohou zpomalovat zápisy do databáze. Měly by tedy být vytvářeny pouze pro data, pro které budou obzvláště výhodné.

3.4.4 Denormalizace

Denormalizace je metoda, která do databáze přidává redundantní data za účelem zrychlení čtení dat. Denormalizace v grafových databázích většinou znamená kopírování hodnot vlastností vrcholů na incidentní hrany. Často se jedná o časové informace. Nevýhodou tohoto procesu je nutná údržba těchto kopií což vede k zpomalení zápisů. Denormalizace je tedy vhodná pouze pro aplikace, kde počet operací pro čtení z databáze mnohonásobně převyšuje počet operací pro zápis.

4 Cestování v grafu


V této kapitole se zaměříme na velkou výhodu grafových databází – cestování v grafu. To může být rozděleno na dva podproblémy: cestování v grafu, kde dopředu známe grafový vzor a cestování v grafu, kde dopředu grafový vzor neznáme. Ne vždy totiž platí, že cestu mezi dvěma vrcholy známe. Často máme pouze počáteční a cílový vrchol a chceme zjistit, zda je jeden z druhého dosažitelný, nebo hledáme nejkratší cestu mezi nimi.

Pro ukázkové příklady v podkapitolách 4.3 a 4.4 je použitý dataset [33] obsahující informace o belgických železničních stanicích a jednosměrných spojeních

mezi nimi. Jednoduchý model znázorňuje obrázek 9. Původní dataset je rozdělen do dvou csv souborů. Jeden uchovává informace o železničních stanicích a druhý spojení mezi nimi. Informace obsahující souřadnice pro hrany byly vypuštěny. Seznam souborů shrnuje tabulka 2.

Tabulka 2: Tabulka souborů pro ukázkou hledání cest.

Typ	Název souboru	Počet řádků	Informace o souboru
Entity	stations.csv	559	Informace o železničních stanicích.
Vztahy	leads_to.csv	1385	Stanice vede do stanice.



Obrázek 9: Model grafové databáze pro ukázkové příklady v této kapitole.

4.1 Procházení grafu

Pro prohledávání grafů od určitého počátečního vrcholu lze použít dva známé grafové algoritmy využívané při cestování v grafu:

1. *Prohledávání do šířky*, označované jako BFS (z anglického Breadth-First Search)
2. *Prohledávání do hloubky*, označované jako DFS (z anglického Depth-First Search)


Oba algoritmy mají časovou složitost $O(|E| + |V|)$.

4.1.1 Prohledávání do šířky

Algoritmus BFS začne v počátečním vrcholu a následně prohledá všechny své sousední vrcholy. Poté projde sousedy sousedů počátečního vrcholu, které ještě nenavštívil a tak postupuje dokud nenavštíví všechny dosažitelné vrcholy.

Tento způsob procházení grafu lze znázornit pomocí kořenového stromu. Kořenem je počáteční uzel. Algoritmus prochází vrcholy grafu po jednotlivých úrovních tohoto stromu. Platí, že nejkratší cesta z počátečního vrcholu do vrcholu v v grafu je rovna hloubce v ve stromu, který vznikne průchodem do šířky. Proto

bývá využíván při hledání nejkratších cest v neohodnoceném grafu. Lze jej efektivně implementovat pomocí fronty vrcholů. Průchod grafem do šířky a strom, vzniklý průchodem algoritmu jsou znázorněny na obrázku 10. Algoritmus začínal ve vrcholu B. Pořadí, v kterém jsou vrcholy procházeny je znázorněno čísly v obdélnících u každého vrcholu.



Obrázek 10: Průchod algoritmu BFS grafem.


4.1.2 Prohledávání do hloubky

Algoritmus DFS začíná v počátečním vrcholu. V aktuálně navštíveném vrcholu vždy přejde do dosud nenavštíveného souseda, pokud takový soused existuje, jinak provede backtracking – vrací se zpět po cestě odkud přišel, dokud nenalezne vrchol jehož soused nebyl navštíven. Skončí jakmile jsou všechny dosažitelné vrcholy navštíveny.

Tento způsob procházení grafu lze opět znázornit pomocí kořenového stromu, kde kořen je počáteční uzel. V tomto stromu pozorování ohledně nejkratších cest, jaké jsme udělali u BFS obecně neplatí. Je výhodný pro předdefinovanou cestu, neboť není tak náročný na paměť. Při implementaci využíváme zásobník. Průchod grafem do hloubky a strom, vzniklý průchodem algoritmu jsou znázorněny na obrázku 11. Algoritmus začínal ve vrcholu B. Pořadí, v kterém jsou vrcholy procházeny je znázorněno čísly v obdélnících u každého vrcholu.

4.2 Předdefinovaná cesta

Často při průchodu grafem předem známe grafový vzor určující cestu, kterou musíme projít, abychom dosáhli požadovaných výsledků pro daný dotaz. Předem víme délku cesty a vrcholové a hranové labely, přes které cesta prochází. Tento průchod grafem budeme označovat jako *předdefinovaná cesta*. Při překladu otázek na dotazy v naší aplikaci pro cestovatelské nadšence s datovým modelem



Obrázek 11: Průchod algoritmu DFS grafem.

na obrázku 7 zjistíme, že všechny grafové vzory z těchto otázek odvozené představují předdefinovanou cestu.

Příkladem může být dotaz odpovídající na otázku „Které destinace navštívil uživatel s identifikátorem X?“. Vidíme, že v dotazu budou jistě figurovat dvě entity, konkrétně: *Uživatel* a *Destinace*. Při pohledu na grafové schéma je zřejmé, že abychom dostali všechny navštívené destinace pro konkrétního uživatele, musíme v grafu projít i přes všechny vrcholy s labelem *Cesta*, které uživatel podniknul. Tyto vrcholy spojují uživatele s destinacemi, které navštívil. Jedná se tedy o known walk, neboť víme, že musíme provést cesty obsahující vrcholy s labely *Uživatel*, *Cesta* a *Destinace*.

Nyní je otázkou, v kterých vrcholech je dobré průchod začít. Volba počátečních vrcholů má často velký vliv na výsledný čas výpočtu. Jednou z možností je začít na vrcholech s labelem *Destinace*. Grafový vzor by pak určoval cestu ze všech vrcholů s labelem *Destinace* přes hrany spojující tyto vrcholy s vrcholy s labelem *Cesta*. Následně pro všechny vrcholy s labelem *Cesta* zkontrolujeme, zda se jich vrchol s labelem *Uživatel*, který má shodný identifikátor s X, zúčastnil. Destinace, které by takto nebyly s uživatelem spojeny, by byly vyfiltrovány. Vyhovující destinace by byly vráceny. Ačkoliv by tento výpočet vedl ke správnému výsledku, procházet přes všechny destinace a tedy i přes všechny cesty není nejvhodnější. Vrcholů, které bychom museli zkontrolovat, je zbytečně mnoho. Obdobně nevhodující by bylo začínat ve vrcholech s labelem *Cesta*. Nejvhodnějším řešením je začít ve vrcholu představujícím konkrétního uživatele. Následně projít přes vrcholy s labelem *Cesta*, kterých se uživatel zúčastnil a dostat se tak ke všem destinacím, které daný uživatel navštívil. Obecně je doporučeno začínat v co nejmenším počtu vrcholů. Výsledný dotaz v Cypheru ukazuje zdrojový kód 3. Do odpovědi je zahrnuta též informace, kolikrát daný uživatel destinace navštívil. Výsledky jsou podle toho seřazeny.

```

1 WITH 3 AS id
2 MATCH (u:User {userId:id})-[:PARTICIPATED]->(:Journey)
3       -[:LED_TO]->(d:Destination)
4 RETURN d.destinationName, COUNT(d) AS count
5 ORDER BY count DESC, d.destinationName ASC;

```

Zdrojový kód 3: Known walk.

4.3 Hledání cesty v neohodnoceném grafu

Nyní se podíváme na hledání cesty v grafu, který je neohodnocený, nebo kde každá hrana má stejnou váhu. Tyto cesty lze hledat i v grafu s ohodnocenými hranami tak, že ohodnocení hran ignorujeme. Počet hran na cestě pak určuje délku cesty. Avšak cest mezi dvěma vrcholy může být obrovské množství. Pokud neomezíme průchod grafem, například pomocí hledání cesty fixní délky, nebo maximální možným počtem hran na cestě, může se stát, že výpočet bude trvat velmi dlouho, nebo v horším případě bude nekonečný. Druhá možnost nastane pokud nezajistíme, že v grafu hledáme opravdu jen cesty a nikoliv sledy. Výpočet by se pak zacyklil a místo výsledku bychom dostali run-time-error.

Důvodů pro hledání cesty mezi dvěma vrcholy může být vícero. Jedním z nich je hledání cesty s nejkratší délkou. Tento problém bývá označován jako *SSSP*. Zkratka je odvozena z anglického *Single-Source Shortest Path*. Dalšími je zjištění dosažitelnosti, nebo hledání cesty o fixní délce. Problém SSSP v neohodnoceném grafu lze vyřešit pomocí algoritmů na prohledávání grafů. Konkrétně se řeší pomocí prohledávání do šířky, neboť systematicky prochází všechny vrcholy, které mají vzdálenost od počátečního vrcholu rovnou k , kde $k \in \mathbb{N}_0$. Začíná pro $k = 0$ a postupně k zvětšuje o 1. V každém kroku kontroluje všechny vrcholy u , které mají z počátečního vrcholu vzdálenost rovnou k . Pokud narazí na cílový vrchol, vrací cestu délky k , kterou se do vrcholu dostal. Algoritmus si pro každý navštívený vrchol může pamatovat vrchol, ze kterého přišel. Tímto způsobem může vrátit i konkrétní cestu, která je posloupností vrcholů a hran. S tímto přístupem je zřejmé, že pokud je cílový vrchol dosažitelný ze začínajícího vrcholu, pak v neohodnoceném grafu nalezneme nejkratší cestu. Nejkratších cest mezi dvěma vrcholy může být více. Pro libovolné $m \in \mathbb{N}$ můžeme takto postupovat i pro nalezení m různých nejkratších cest pro dva dané vstupní vrcholy.

V databázi ArangoDB lze cesty mezi stanicemi obsahující 1 až 4 hrany najít pomocí dotazu ve zdrojovém kódu 4. Na řádce 2 vyfiltrujeme ty sledy, které obsahují cyklus a specifikujeme strategii prohledávání do šířky. Výsledky jsou seřazeny podle počtu hran na cestě. Tabulka 3 ukazuje výsledek tohoto dotazu po zavolání.

4.4 Hledání cesty v ohodnoceném grafu

Délka cesty mezi počátečním a koncovým vrcholem v ohodnoceném grafu je dána součtem ohodnocení hran na cestě. Tedy nejmenší počet hran na cestě nutně ne-

```

1  FOR v,e,p IN 1..4 OUTBOUND 'Station/157' LEADS_TO
2  OPTIONS {uniqueVertices: 'path', order: 'bfs'}
3      FILTER p.vertices[-1]._id == 'Station/1061'
4      LET distance = LENGTH(p.edges[*])
5      LET stations = p.vertices[*].stationName
6      SORT distance
7      RETURN {
8          stations,
9          distance
10     }

```

Zdrojový kód 4: Cesty v neohodnoceném grafu.

Tabulka 3: Výsledná tabulka pro dotaz ve zdrojovém kódu 4.

stations	distance
BILZEN, BOKRIJK, KIEWIT, SCHULEN	3
BILZEN, DIEPENBEEK, HASSELT, SCHULEN	3
BILZEN, BOKRIJK, KIEWIT, HASSELT, SCHULEN	4
BILZEN, DIEPENBEEK, HASSELT, KIEWIT, SCHULEN	4
BILZEN, DIEPENBEEK, HASSELT, ZONHOVEN, SCHULEN	4

znamená, že součet ohodnocení hran je menší než na jiné cestě obsahující více hran. Z tohoto důvodu zde nemůžeme pro vyřešení SSSP použít lehce modifikovaný algoritmus, který nám řešil problém v předchozí části.

Jedním ze způsobů, jak vyřešit SSSP, je udržování a aktualizování nejkratších nalezených cest do již navštívených vrcholů. Tento princip je známý z významného algoritmu pro řešení SSSP – Dijkstrova algoritmu. Je ho využito ve zdrojovém kódu 5 v jazyku Gremlin. Výsledek, který dostaneme shrnuje tabulka 4. Celková vzdálenost v je zaokrouhlená na celé metry.

Tabulka 4: Výsledná tabulka pro dotaz ve zdrojovém kódu 5.

stations	stationsCount	totalLength
SCHAERBEEK, BUDA, VILVOORDE, EPPEGEM, WEERDE, MECHELEN	6	18 206 m
SCHAERBEEK, VILVOORDE, EPPEGEM, WEERDE, MECHELEN	5	18 269 m
SCHAERBEEK, MECHELEN	2	19 833 m

Z vrácených výsledků vidíme, že nejkratší délka železnic mezi stanicemi SCHAEERBEEK a MECHELEN má délku 18.2 kilometrů. Na této cestě projdeme přes 6 stanic. Jen o 50 metrů je delší druhá cesta, která obsahuje o jednu zastávku méně. Třetí výsledek je delší o více než 1.5 kilometru a jedná se o přímý spoj.

Zde též platí, že cest může být mezi dvěma vrcholy opravdu mnoho. Obzvláště ve velikých grafech. Proto se často z časových důvodů nejkratší cesta

```

1 g.withSack(0.0).V().
2   has("Station", "stationId", 1048).
3   repeat(outE("LEADS_TO").
4     sack(sum).by("length").
5     inV().as("visited").
6     simplePath().
7     group("minDist").
8     by().by(sack().min()).
9     filter(project("currMinDist", "sackDist").
10      by(select("minDist").select(select("visited")))).
11      by(sack()).
12      where("currMinDist", eq("sackDist")))).
13 until(has("Station", "stationId", 810)).
14 order().
15   by(sack(), asc).
16 limit(3).
17 project("stations", "stationsCount", "totalLength").
18   by(path().
19     unfold().
20     hasLabel("Station").
21     values("stationName").
22     fold()).
23   by(path().count(local).math('(_+1)/2')).
24   by(sack()).
25 fold()

```

Zdrojový kód 5: Hledání nejkratší cesty v ohodnoceném grafu.

aproximuje. Pokud má vrchol na možné cestě výstupní stupeň větší než nějaký limit l (například $\deg_{out}(u) > 10\,000$), cestu přes něj nepočítáme, neboť bychom museli procházet každou výstupní hranu což by bylo výpočetně náročné.

Výpočet lze též omezit zadáním horního limitu pro délku cesty. Pokud délka cesty tento limit přesáhne, tak tato cesta je zavrhnuta. Limit můžeme určit tak, že spočítáme nejkratší cestu v grafu při zanedbání ohodnocení hran. Limit bude roven součtu ohodnocení hran na této cestě.

Dijkstrův algoritmus nefunguje pro SSSP v grafu, kde se mohou vyskytovat hrany se záporným ohodnocením. V těchto grafech je proto nutné použít Bellman-Fordův algoritmus. Pro hledání nejkratších cest mezi všemi dvojicemi vrcholů (All-Pairs Shortest Paths – APSP) grafu je vhodný Floyd-Warshallův algoritmus.

5 Algoritmy

Tato kapitola byla napsána pomocí knih [34] a [30]. Dále byla využita dokumentace knihovny Graph Data Science Library [19] a zdroje [35] a [4].

V této kapitole si ukážeme řadu užitečných algoritmů, které jsou určené pro práci s grafem a jsou tedy v určitých situacích vhodné aplikovat při dotazech na grafovou databázi. Tyto algoritmy používají především OLAP systémy. Umož-

ňují nám efektivně hledat nejkratší cesty mezi vrcholy, nacházet vrcholy, které pro nás mohou být svým způsobem důležité, nebo třeba hledat skupinky navzájem propojených vrcholů v grafu. Tyto algoritmy a mnohé další obsahuje knihovna s názvem `Graph Data Science Library`. Tuto knihovnu lze do datečně nainstalovat do databáze Neo4j. Zkráceně ji budeme označovat GDS.

Pro nejefektivnější běh algoritmů používá GDS k reprezentaci dat grafu speciální formát grafu uložený dočasně v paměti. Jedná se o strukturu vrcholů a hran, jejichž vlastnosti mohou být pouze číselné. Každý takový graf je pojmenován a díky tomu na něj můžeme odkazovat v algoritmech. Tyto odkazy jsou uloženy v *grafovém katalogu*. Graf lze vytvořit více způsoby. V práci je použitý způsob vytvoření grafu pomocí *Cypher projekce*.

Algoritmy pak mohou běžet ve třech režimech:

- *stream* – výsledky algoritmu obdržíme jako výsledek dotazu.
- *mutate* – výstup algoritmu aktualizuje graf v paměti.
- *write* – zapíše výsledek algoritmu zpět do databáze Neo4j.

5.1 Algoritmy pro hledání cesty v grafu

V praxi je užitečné v grafu najít rychle optimální cestu mezi dvěma, či více vrcholy. Tento problém potřebují řešit například nástroje pracující s grafy reprezentující mapy, které hledají vhodné trasy mezi body na mapě. Dalšími příklady optimalizačních problémů jsou řízení dodavatelských řetězců, hledání nejvhodnějšího autobusového spojení a analýza počítačové sítě. Pro řešení tohoto problému vznikly různé algoritmy. Každý pracuje odlišně a je výhodný pro různé poddruhy problémů. Pár z nich si zde představíme.

5.1.1 Dijkstra

Jeden z nejznámějších algoritmů pro hledání nejkratší cesty. Lze jej aplikovat na neohodnocené grafy, nebo grafy s kladným ohodnocením hran. Jedná se o hladový algoritmus, který k specifikovanému vrcholu vydá nejkratší cestu z tohoto vrcholu do všech ostatních vrcholů. Lze jej také omezit, aby iteroval jen dokud nenajde nejkratší cestu ke konkrétnímu cílovému vrcholu. Správné řešení je dosaženo díky pamatování si dosud nejkratších nalezených cest do již navštívených vrcholů. V každé iteraci se pak vybere jeden vrchol s nejkratší nalezenou cestu ze všech, které dosud nebyly vybrány a následně aktualizuje všechny nejkratší cesty vedoucí přes tento vybraný vrchol. Pokud je nějaký vrchol nedosažitelný nebo ještě nebyl navštívený, má hodnotu ∞ .

Nevýhodou tohoto algoritmu je, že pro nalezení nejkratší cesty pro 2 zadané vrcholy je v nejhorším případě potřeba nalézt všechny nejkratší cesty do ostatních vrcholů, než se algoritmus dostane k požadovanému výsledku. To nastává v případě, kdy mezi dvěma vrcholy je nejkratší cesta nejdelší ze všech nejkratších cest z počátečního vrcholu do ostatních vrcholů.

5.1.2 A*


A* pracuje podobně jako Dijkstraův algoritmus. Avšak často dosahuje výsledku rychleji díky dodatečné informaci, kterou dostane na vstupu. Této informaci se říká heuristika. Je to funkce $h: V \rightarrow \mathbb{R}^+$ odhadující délku cesty ze všech vrcholů do cílového vrcholu. Pro správný výsledek by heuristika měla být optimistická, tedy odhad vzdálenosti by měl být nejvýše roven skutečné vzdálenosti. Platí, že čím lépe odhadneme heuristiku tím rychleji algoritmus najde řešení. Dijkstraův algoritmus je speciálním případem A*. Pro něj platí $h(v) = 0$ pro všechny vrcholy $v \in V$. Pro svůj rychlý výpočet je například implementován ve videohrách.

Rozhodnutí do jakého vrcholu bude algoritmus pokračovat je provedeno na základě funkce $f(n) = g(n) + h(n)$ pro každý navštívený vrchol n . Funkce $g(n)$ představuje součet ohodnocení nejkratší cesty z počátečního vrcholu přes již navštívené vrcholy do n . Funkce $h(n)$ je vstupní heuristika. V každé iteraci pak algoritmus pokračuje vrcholem, pro který je hodnota funkce f nejmenší.

V GDS lze A* použít například pro vrcholy reprezentující nějakou lokaci, která je přesně určena pomocí zeměpisné šířky a délky. Geografické souřadnice nám slouží jako část heuristické funkce.

5.1.3 Minimální kostra grafu

Dalším, mezi informatiky dobře známým, problémem je hledání minimální kostry v souvislém grafu. Kostru grafu lze definovat jako podgraf grafu G , který je stromem obsahujícím všechny vrcholy původního grafu. My požadujeme, aby kostra byla minimální, tedy aby součet ohodnocení hran v nalezeném podgrafu byl ze všech možných koster nejmenší. Vstupem algoritmu hledajícího minimální kostru grafu je souvislý neorientovaný graf G s ohodnocenými hranami. Příklad minimální kostry grafu je na obrázku 12.



Obrázek 12: Minimální kostra grafu.

Problém kostry grafu má více variant. Můžeme též hledat maximální kostru

grafu, nebo omezit počet vrcholů v kostře na $k \in \mathbb{N}$ tomuto problému se říká *k-spanning tree*.

GDS knihovna algoritmus na hledání kostry obsahuje. Konkrétně nabízí Jarníkovo-Primův algoritmus, poprvé popsáný v roce 1930 českým matematikem Vojtěchem Jarníkem. Tento iterativní hladový algoritmus vyžaduje na vstupu specifikovat počáteční vrchol s . Postupně je z něj vytvářen strom T tak, že v každém kroku je k T připojena jedna hrana. Vždy je vybrána hrana s nejmenší vahou, která vede z vrcholu v T do vrcholu mimo T . Pokud neexistuje hrana, která by šla do stromu přidat, výpočet skončí a vrátí T , kde T je minimální kostra komponenty vstupního grafu obsahující s . Pokud při implementaci využíváme binární prioritní frontu dostaneme celkovou složitost $O(|E| \log_2 |V|)$.

Tento algoritmus lze využít pro nejlevnější propojení měst vodním potrubím, kde nižší ohodnocení hran znamená menší náklady. Dalším využitím je aproximace problémů patřících do třídy NPTIME, jako je například problém obchodního cestujícího.

5.1.4 Random walk

Random walk provádí náhodné sledy zadané délky. Jedná se o průchod grafem, během kterého jsou náhodně vybírány hrany. V „hloupé“ verzi algoritmu je v každém vrcholu pravděpodobnost vybrání hrany uniformní a nezáleží na předchozích výběrech. GDS nabízí tzv. Random walk druhého řádu. U tohoto algoritmu se specifikují dva parametry:

- `returnFactor` – vyjadřuje snahu algoritmu se vracet zpět do vrcholu, který byl navštíven naposledy. Hodnoty menší než 1 pravděpodobnost tohoto výběru zvyšují.
- `inOutFactor` – vyjadřuje snahu algoritmu zůstat či nezůstat v blízkosti počátečního vrcholu. Čím vyšší hodnota je zadána, tím bude průchod grafem lokálnější.

V „hloupé“ verzi jsou oba parametry nastaveny na hodnotu 1. Pravděpodobnost výběru též můžeme ovlivnit pomocí ohodnocených hran. Vlastnost hrany, která je vyšší než jedna pravděpodobnost výběru této hrany zvyšuje. Naopak hodnoty z intervalu $(0, 1)$ pravděpodobnost zmenšují.

Random walk se používá jako součást jiných algoritmů, kde je potřeba určité množství náhodných, ale navzájem propojených vrcholů. V následující ukázce byl algoritmus použit na železniční stanice 9 z předchozí kapitoly. Algoritmus začínal ve stanici s identifikátorem 9. Tabulka 5 ukazuje výsledky algoritmu. Pro jedno nastavení parametrů jsou ukázány tři náhodné cesty. Cesta je reprezentována ve druhém sloupci řádkem identifikátorů vrcholů oddělených středníkem, přes které prochází. V třetím sloupci je pro každou cestu spočítána vzdálenost vzdušnou čarou z počátečního do cílového vrcholu naznačující, jak lokální průchod algoritmus provedl.

Tabulka 5: Random walk.

Parametry	Vrcholy na cestě	Vzdálenost
returnFactor = 20; inOutFactor = 0,2	9; 132; 187; 541; 814; 142; 732; 644	29 596 m
	9; 686; 1134; 1270; 326; 1061; 523; 19	38 943 m
	9; 1238; 553; 1174; 368; 648; 916; 1260	19 693 m
returnFactor = 0,2; inOutFactor = 20	9; 132; 9; 132; 9; 132; 686; 132	8 181 m
	9; 686; 9; 686; 9; 686; 9; 686	9 587 m
	9; 132; 9; 686; 9; 686; 9; 132	8 181 m

5.2 Algoritmy pro míru centrality

V rámci grafu můžeme identifikovat důležitost a vliv vrcholů v grafu pomocí algoritmů centrality. Můžeme detekovat jedince, které jsou svým způsobem v grafu významější než ostatní. Tyto algoritmy se dají využít například k hledání kritických částí v telekomunikačních nebo počítačových sítích, tedy těch přes které proudí spousta informací a jejichž výpadek by představoval velké potíže. Dále je můžeme použít k hledání vlivných lidí v rámci organizace, hledání odlehlých dat, které mohou odhalit, že dochází k podvodům a podobně.

5.2.1 Degree Centrality

Nejznámější a nejjednodušší mírou centrality je degree centrality. Tato míra každému vrcholu v grafu přiřazuje skóre rovné jeho stupni. Stupeň vrcholu může být buď vstupní, výstupní, nebo kombinovaný. Vrcholy s vyšším stupněm lze obecně považovat za důležitější, neboť přes ně může proudit více informací díky většímu počtu hran. Příkladem může být graf reprezentující železniční síť. Čím více spojení má železniční stanice, tím spíše se jedná o významější stanici.

V sociálních sítích mívají vrcholy i stupně v řádu stovek milionů. Těmto vrcholům říkáme *super-uzly*. Abychom prošli všechny sousedy super-uzlu potřebujeme značně více času, než v případě „obyčejného“ vrcholu. To se negativně projevuje v časové odezvě u dotazů pracujících s takovými vrcholy. Degree centrality nám umožňuje takové vrcholy odhalit.

5.2.2 Closeness Centrality

Myšlenkou closeness centrality je identifikovat nejvlivnější vrchol v grafu na základě toho, jak rychle je možné se z něj dostat do ostatních vrcholů. Konkrétně je to vrchol, pro který je součet nejkratších cest do všech ostatních vrcholů co nejmenší. V případě nesouvislého grafu lze využít *harmonic centrality*, která se umí vypořádat s nedosažitelnými vrcholy. Skóre vrcholu $u \in V$ v grafu $G = \langle V, E \rangle$ se pak počítá podle vzorce

$$closenessCentrality(u) = \frac{1}{\sum_{v \in V \setminus \{u\}} dist(u, v)}, \quad (1)$$

nebo se normalizuje

$$\text{normalizedClosenessCentrality}(u) = \frac{|V| - 1}{\sum_{v \in V \setminus \{u\}} \text{dist}(u, v)}. \quad (2)$$

5.2.3 Betweenness Centrality

Algoritmus pro výpočet betweenness centrality spočítá nejkratší cesty mezi všemi páry různých vrcholů v grafu. Každý vrchol poté obdrží skóre, které je tím vyšší, čím více nejkratších cest vede přes daný vrchol. Tyto hodnoty mohou být klíčové například v grafu, kde vrcholy reprezentují křižovatky a hrany představují cesty mezi nimi. Informace o tom, kterými křižovatkami prochází nejvíce nejkratších cest, můžeme využít pro odhad lokací, kde se pravděpodobně bude pohybovat nejvíce lidí.

Algoritmy pro closeness a betweenness centrality mohou být v případě velkých grafů výpočetně dost náročné. Proto se často přistupuje k jiným, ne zcela přesným, zato mnohonásobně rychlejším, algoritmům.

5.2.4 PageRank

S tímto algoritmem přišla na trh společnost Google. Byl určen pro hodnocení významnosti webových stránek, kde webové stránky si lze představit jako vrcholy grafu. Hrany mezi nimi reprezentují odkazy na stránkách odkazujících na jiné stránky. Důležitost vrcholu je určena nejen důležitostí vrcholu samotného, ale také důležitostí vrcholů na tuto stránku odkazujících. Vysoké skóre vrcholu tedy znamená, že je vrchol propojen s vrcholy, které mají též vysoké skóre.


Toto řešení je založeno na vlastních vektorech a stochastických maticích z lineární algebry. Výpočet skóre většinou vede na nekonečný výpočet a proto se omezuje počet iterací tohoto výpočtu, nebo se udává maximální možná odchylka mezi výsledky iterací. PageRank se používá pro orientované grafy. Pro neorientované grafy lze použít algoritmus *eigenvector centrality*.

5.2.5 Použití algoritmů pro míru centrality

Výsledky aplikace zmíněných algoritmů pro měření centrality na graf z obrázku 13 je znázorněn v tabulce 6.

Tabulka 6: Výsledky měření centrality.

Vrchol	A	B	C	D	E	F	G
Degree Centrality	4	3	4	4	3	2	2
Closeness Centrality	0,75	0,6	0,75	0,75	0,67	0,55	0,6
Betweenness Centrality	3,33	0	1,33	1,33	2,67	1	1,33
Eigen Vector Centrality	0,45	0,41	0,49	0,49	0,32	0,14	0,17



Obrázek 13: Příklad grafu, na kterém jsou prováděny algoritmy.

5.3 Detekce komunit

Tyto algoritmy lze využít pro hledání určitých skupin vrcholů, které mají mezi sebou více hran, než mají s ostatními vrcholy grafu. Těmto skupinám říkáme komunity. Příklad lze nalézt v sociálních sítích, kde můžeme sledovat komunity blízkých přátel, které tvoří shluky propojených vrcholů. Následně lze z těchto informací odhadovat chování jednotlivců podle členů jejich komunity. Znalost komunit lze též využít pro doporučování produktů uživatelům s podobným nákupním chováním.

Algoritmy pro detekci komunit se dělí na *deterministické* a *nedeterministické*. Deterministické vrací pro stejný graf vždy stejný výsledek, zatímco výsledek u nedeterministických může být pro stejný graf mírně odlišný. Mezi deterministické se řadí počítání trojúhelníků, výpočet shlukovacího koeficientu, nebo hledání komponent. Mezi nedeterministické patří například Label Propagation, nebo Louvain Modularity.

5.3.1 Počítání trojúhelníků a shlukovacího koeficientu

Algoritmus pro každý vrchol určí počet *trojúhelníků*, kterých je daný vrchol součástí. Trojúhelník je zde definován jako skupina tří navzájem propojených vrcholů. Trojúhelníky nám pomáhají určit do jaké míry jsou vrcholy v našem grafu propojeny. V hustých grafech, lze obvykle nalézt více trojúhelníků. Algoritmus je oblíbený při analýze sociálních sítí, kde pomáhá detekovat komunity, nebo zkoumání skupin webových stránek s podobným námětem podle odkazů mezi nimi.

Znalost počtu trojúhelníků lze využít též pro výpočet *shlukovacího koeficientu* vrcholu, který určuje pravděpodobnost, s jakou jsou jeho sousedé propojeni – tvoří s ním trojúhelník. Shlukovací koeficient vrcholu u je pak určen vzorcem

$$ClusteringCoefficient(u) = \frac{2 * TriangleCount(u)}{deg(u) * (deg(u) - 1)}. \quad (3)$$

Pro ukázkový graf na obrázku 13 počet trojúhelníků a shlukovací koeficient jednotlivých vrcholů zobrazuje tabulka 7. Vidíme, že vrchol A je součástí tří

trojúhelníků, které jsou tvořeny vrcholy A-B-C, A-B-D a A-C-D. Stupeň vrcholu je 4. Dosazením do vzorce 3 dostáváme shlukovací koeficient 0.5.

Tabulka 7: Počet trojúhelníků a shlukovací koeficient.

Vrchol	A	B	C	D	E	F	G
Triangle Count	3	3	4	4	1	0	0
Clustering Coefficient	0,5	1	0,67	0,67	0,33	0	0

5.3.2 Hledání komponent

Nalezení komponent v grafu je užitečné pro pochopení našich dat. Algoritmy pro tuto úlohu jsou rychlé. Mohou být využívány v grafech, které se často aktualizují pro detekci nových vrcholů mezi skupinami. Toho lze pak využít při různých analýzách. Existují algoritmy pro hledání silně a slabě souvislých komponent. Pro graf na obrázku 13 nám algoritmus pro hledání slabě souvislých komponent vrátí, že všechny vrcholy grafu jsou součástí jedné komponenty.

5.3.3 Algoritmus Louvain

Algoritmus se snaží maximalizovat modularitu komunit. Modularita je způsob jakým můžeme měřit kvalitu komunit. Porovnává komunity v grafu s náhodným grafem, který vznikne odstraněním hran v původním grafu a následným přidáním těchto hran mezi dva náhodně zvolené nepropojené vrcholy. U náhodného grafu se předpokládá rovnoměrné propojení těchto vrcholů. Modularita nabývá hodnot z intervalu $\langle -1, 1 \rangle$. Čím je hodnota vyšší, tím jsou vrcholy v komunitách propojenější. Výpočet modularity je počítán vzorcem

$$M = \frac{1}{2m} \sum_{u,v} [A_{uv} - \frac{k_u k_v}{2m}] \delta(C_u, C_v), \quad (4)$$

kde

- u a v jsou vrcholy,
- m je součet přes všechna ohodnocení hran,
- A_{uv} je váha hrany mezi vrcholy u a v ,
- k_x je součet přes všechna ohodnocení hran incidentních s x
- a $\delta(C_u, C_v) = \begin{cases} 1 & \text{jestliže } u \text{ i } v \text{ patří do stejné komunity,} \\ 0 & \text{jinak.} \end{cases}$

Podíl $\frac{k_u k_v}{2m}$ ve vzorci 4 odpovídá náhodnému grafu mající stejnou distribuci stupňů a tedy vyjadřuje očekávanou sumu ohodnocení hran mezi dvěma vrcholy.

Na začátku každý vrchol tvoří komunitu. V neohodnoceném grafu má každá hrana váhu 1. Algoritmus má dva kroky:

1. Každý vrchol v grafu je přiřazen do nějaké komunity. Následně dochází k vyhodnocování změny modularity, pokud vrchol přeřadíme do jiné komunity. Vyhodnocuje se pomocí vzorce 4. Cílem je najít nejlepší rozřazení jednotlivých vrcholů do komunit.
2. Každá komunita tvoří vrchol nového grafu. Ohodnocené hrany v novém grafu představují jak jsou komunity mezi sebou propojeny. Hrana propojující dva nově vzniklé vrcholy má váhu, která je součtem vah hran mezi komunitami, které tyto vrcholy reprezentují. Tento nový graf bude vstupem v další iteraci.

Algoritmus iteruje tak dlouho, dokud dochází ke zvyšování modularity ve vzniklých komunitách.

Pro ukázkový graf 13 nám algoritmus z knihovny GDS rozdělil vrcholy do dvou komunit. Výsledky shrnuje tabulka 8.

Tabulka 8: Algoritmus Louvain.

Vrchol	A	B	C	D	E	F	G
Komunita	2	2	2	2	6	6	6


6 Testování vybraných implementací

Pro testování byl použit dataset [36]. Pro testování byl též vytvořen csv soubor obsahující identifikátory všech uživatelů v síti. Seznam souborů shrnuje tabulka 9. Průměrný stupeň vrcholu je 5,2. Medián a modus je 1. První kvartil je roven 1 a třetí kvartil je roven 3. Největší stupeň ze všech vrcholů má vrchol s identifikátorem 1 072, který má stupeň 28 754. Částečnou distribuci stupně vrcholů zobrazuje obrázek 14. Pro zvýšení přehlednosti bylo na vertikální ose použito logaritmické měřítko o základu 10. Horizontální osa zobrazující stupně vrcholů byla omezena na interval $\langle 0, 2000 \rangle$.

Testování probíhalo na notebooku s operační pamětí o velikosti 16 GB. Notebook byl po celou dobu testování napájen. Konfiguraci databází jsem ponechal v původním stavu, neboť tak podávaly nejlepší výsledky. Pouze jsem upravil velikost Java Heap na 4 GB. U testování výkonu procházení grafu a hledání nejkratší cesty jsem provedl první pokus, abych viděl, jak funguje cache. Následně byl každý dotaz proveden desetkrát. Z těchto výsledků pak byla vypočítána průměrná doba dotazu.

Tabulka 9: Tabulka souborů pro experimentování s databázemi.

Typ	Název souboru	Počet	Informace o souboru
Entity	users.csv	1 134 890	Identifikátory uživatelů.
Vztahy	com-youtube.ungraph.tsv	2 987 624	Přátelství mezi uživateli.
Vlastnosti	properties.csv	1 134 890	Jméno a věk uživatelů.




Obrázek 14: Distribuce stupně vrcholů.

6.1 Výsledky

První jsem testoval vkládání a mazání vrcholů a hran v databázích. Data do databáze Neo4j byla vložena pomocí klauzule LOAD CSV v transakcích. Pro vložení dat do databáze ArangoDB byl použit nástroj arangoimport. Pro databázi OrientDB byl použit nástroj ETL. Mazání vrcholů a hran probíhalo pomocí dotazovacího jazyka dané databáze. V OrientDB jsem mazal vrcholy pouze pomocí SQL. Výsledky testu zobrazuje obrázek 15.

Následně jsem otestoval výkon databází pomocí osmi dotazů. Inspiroval jsem se dotazy používanými ve zdroji [37]. První čtyři dotazy testují průchod grafem. Další dva hledají nejkratší cestu. Pro poslední dva dotazy jsem do databáze přidal pomocí výše zmíněných importovacích nástrojů vlastnosti ze souboru properties.csv. Sloužily k otestování filtrování a agregování. Na tyto vlastnosti nebyl použitý index. Všechny dotazy jsou shrnuty v tabulce 10. Obrázky 16 a 17 ukazují průměrnou dobu trvání jednotlivých dotazů.



Obrázek 15: Průměrné výsledky dotazů vkládání a mazání.

Tabulka 10: Tabulka použitých dotazů při testování databází.

Dotaz	Popis dotazu	Výsledek
Q1	Spočítá sousedy vrcholu s userId 1 do hloubky 2.	7 176
Q2	Spočítá sousedy vrcholu s userId 1 do hloubky 3.	240 249
Q3	Spočítá sousedy vrcholu s userId 1 do hloubky 4.	814 122
Q4	Spočítá sousedy vrcholu s userId 1 do hloubky 5.	1 051 030
Q5	Najde nejkratší neorientovanou cestu mezi dvěma vrcholy s userId 12000 a 1047.	3 hrany
Q6	Hledá nejkratší orientovanou cestu z vrcholu s userId 12000 do vrcholu s userId 1047, přičemž cesta neexistuje.	null
Q7	Vrátí počet uživatel starších 75 let, jejichž jméno začíná na řetězec „Ma“.	13 779
Q8	Vrátí průměrný věk uživatelů jmenujících se „James“.	56,574 let


6.2 Shrnutí

Následuje shrnutí výsledků výkonostních testů jednotlivých databází.


6.2.1 OrientDB

Při vkládání a mazání byly mnou naměřené výsledky i více než 14krát horší. Přitom bylo dodrženo doporučení z dokumentace – hodnota WAL nastavena na hodnotu `false`. Mnou naměřené výsledky databází OrientDB a Neo4j odpovídají výsledkům experimentu [38].

Pro porovnání výkonu zpracování dotazů Q1-Q8 jsem dotazy zadával jak v jazyce SQL pro OrientDB databázi, tak v jazyce Gremlin. Pro zlepšení výsledků jsem také zkusil dotazy Q1-Q6 spustit v databázi používající lightweight hrany (dotazy s nimi jsou na obrázku 16 označeny jako LE). V případě jazyka Gremlin



Obrázek 16: Průměrné výsledky dotazů Q1-Q6.



Obrázek 17: Průměrné výsledky dotazů Q7 a Q8.

se pak vyhodnocení dotazů v databázi s lightweight hranami více než dvakrát zrychlilo. Pokud tedy není potřeba uchovávat na hranách vlastnosti, z testování plyne, že je dobré kvůli výkonu i prostoru v uložení použít lightweight hrany.

Vyhodnocení většiny dotazů bylo v jazyce Gremlin výrazně rychlejší, než v případě SQL. Dotaz Q5 byl rychlejší v OrientDB SQL pomocí zabudované funkce `SHORTEST_PATH`. Pomocí jazyka Gremlin jsem nedostal odpověď na dotaz Q6 ani po čtyřiceti minutách běhu. Výsledku se dá dočkat pokud omezíme průchod grafem nastavením limitu pro délku cesty.

V porovnání s ostatními databázemi však OrientDB silně zaostávala. Z výsledků zkoumání [37] jsem očekával, že vyhodnocení dotazů Q3 a Q4 bude v OrientDB rychlejší než v Neo4j. Mnou naměřené výsledky však byly i více než desetkrát horší.

Dokumentace OrientDB není příliš přehledná v porovnání s ostatními. Setkal jsem se s odkazy na neexistující webové stránky a to i v rámci webového rozhraní. Problémy s databází se mi řešily hůře než u ostatních, neboť komunita OrientDB na internetu není tak velká. Při importování dat se někdy do databáze nevložily všechny vrcholy a hrany, i když soubor určený pro import byl stejný.

6.2.2 ArangoDB

Databáze v prvním testu zvládla dobře vkládání a mazání dat. Překvapilo mě vkládání hran, které bylo rychlejší než u databáze Neo4j. Při prvním i druhém testování se většinou pohybovala mezi dalšími dvěma testovanými databázemi. Jediným větším problémem byl dotaz Q6 na hledání nejkratší cesty, mezi dvěma nepropojenými vrcholy. Ani po čtyřiceti minutách se nezastavil, když jsem využil vestavěnou funkci `SHORTEST_PATH`.

ArangoDB má poměrně efektivní cache. Neboť dotazy opakovaně provedené

se vždy hodně lišily od prvního pokusu, který jsem nezahrnul do měření. Například první pokus pro dotaz Q4 trval 41,945 sekund. Následující pokusy v průměru pouze třetinu toho času.

6.2.3 Neo4j

Neo4j byla dle očekávání ve zpracování dotazů nejrychlejší. Při práci s databází jsem nenarazil na žádný problém. Jedním z důvodů jistě bylo zaměření databáze přímo na grafy, oproti multimodelovým konkurentům.

Závěr

Cílem práce bylo představit grafové databáze. Popsal jsem principy ukládání a práci s daty ve formě grafu. V práci jsem se věnoval modelování grafových dat a následně hlavní přednosti grafových databází – cestování grafem. Představil jsem tři kategorie grafových algoritmů používaných v grafových databázích. Konkrétně to byly algoritmy pro hledání cest, míru centrality a detekci komunit.

V praktické části jsem se věnoval vybraným známým implementacím grafových databází a ukázkám jejich použití. Demonstroval jsem na nich jednotlivé problémy zmiňované v textu práce. Následně jsem vybral vhodný dataset, na kterém byly vybrané implementace experimentálně porovnány.

Práce by se dala rozšířit o porovnání více implementací grafových databází. Toto porovnání by bylo mnohem přínosnější provést za přísnějších podmínek, které by zajistilo mnohem vyšší přesnost testování. Také by mohl být věnována větší pozornost grafovým databázím implementující RDF model, či hypergraf.

Conclusions

The aim of the thesis was to introduce graph databases. I described the principles of storing and working with data in the form of a graph. In the thesis, I focused on graph data modeling and subsequently the main advantages of graph databases – graph traversal. I introduced three categories of graph algorithms used in graph databases. Specifically, these were algorithms for path finding, centrality measure, and community detection.

In the practical part, I focused on selected well-known implementations of graph databases and examples of their usage. I demonstrated on them the individual problems mentioned in the text of the thesis. Subsequently, I selected a suitable dataset on which the selected implementations were experimentally compared.

The thesis could be expanded by comparing more implementations of graph databases. This comparison would be much more beneficial if conducted under stricter conditions to ensure much higher testing accuracy. Also, greater attention could be devoted to graph databases implementing the RDF model or hypergraph.

Literatura

- [1] DB-Engines. 2024. Dostupný také z: <https://db-engines.com/en>.
- [2] Wilson, Robin James. *Introduction to graph theory*. 4th Edition. 1996. ISBN 0-582-24993-7.
- [3] Ramba, Jaroslav. *Úvod do grafové terminologie / Ramba.cz*. 2024. Dostupný také z: <https://www.ramba.cz/blog/grafova-terminologie-a-dostupne-technologie>.
- [4] Bělohávek, Radim. 2024. Dostupný také z: <http://belohlavek.inf.upol.cz/vyuka/DiskretniStruktury-2020.pdf>.
- [5] 2024. Dostupný také z: <https://home.zcu.cz/~ryjacek/students/DMA/skripta/8.pdf>.
- [6] Robinson, Ian; Webber, Jim; Eifrem, Emil. *Graph databases*. 2nd Edition. 2015. ISBN 978-1-491-93200-1.
- [7] *A Guide to Graph Databases*. 2024. Dostupný také z: <https://www.influxdata.com/graph-database/>.
- [8] Besta, Maciej; Gerstenberger, Robert; Peter, Emanuel aj. Demystifying Graph Databases: Analysis and Taxonomy of Data Organization, System Designs, and Graph Queries. *ACM Computing Surveys*. 2023, roč. 56, č. 2, s. 1–40. Dostupný také z: <http://dx.doi.org/10.1145/3604932>. ISSN 1557-7341.
- [9] IONOS. *IONOS Digital Guide*. 2024. Dostupný také z: <https://www.ionos.com/digitalguide/hosting/technical-matters/graph-database/>.
- [10] McCreary, Dan. 2024. Dostupný také z: <https://dmccreary.medium.com/how-to-explain-index-free-adjacency-to-your-manager-1a8e68ec664a>.
- [11] graph.build. *Graph Models, Structures and Knowledge Graphs*. 2024. Dostupný také z: <https://graph.build/resources/graph-models>.
- [12] *Série Znalostní grafy: Díl 2: Datový model RDF*. 2024. Dostupný také z: <https://data.gov.cz/%C4%8Dl%C3%A1nky/znalostn%C3%AD-grafy-02-rdf>.
- [13] Štráfelda, Jan. *Knowledge Graph*. 2024. Dostupný také z: <https://www.strafelda.cz/knowledge-graph>.
- [14] 2024. Dostupný také z: http://langer.zam.slu.cz/teaching/dbaii/olap_oltp.pdf.
- [15] Amazon Web Services, Inc. 2024. Dostupný také z: <https://aws.amazon.com/neptune>.
- [16] TigerGraph. 2024. Dostupný také z: <https://www.tigergraph.com>.
- [17] Allegrograph.com. 2024. Dostupný také z: <https://allegrograph.com/>.

- [18] janusgraph.org. 2024. Dostupný také z: [⟨https://janusgraph.org⟩](https://janusgraph.org).
- [19] *Neo4j Documentation*. 2024. Dostupný také z: [⟨https://neo4j.com/docs⟩](https://neo4j.com/docs).
- [20] *Neo4j Developer Center*. 2024. Dostupný také z: [⟨https://neo4j.com/developer⟩](https://neo4j.com/developer).
- [21] *OrientDB Documentation*. 2024. Dostupný také z: [⟨https://www.orientdb.com/docs/last/index.html⟩](https://www.orientdb.com/docs/last/index.html).
- [22] *ArangoDB Documentation*. 2024. Dostupný také z: [⟨https://docs.arangodb.com⟩](https://docs.arangodb.com).
- [23] ArangoDB. *Index Free Adjacency or Hybrid Indexes for Graph Databases*. 2024. Dostupný také z: [⟨https://arangodb.com/2016/04/index-free-adjacency-hybrid-indexes-graph-databases/⟩](https://arangodb.com/2016/04/index-free-adjacency-hybrid-indexes-graph-databases/).
- [24] W3.org. *SPARQL Query Language for RDF*. 2024. Dostupný také z: [⟨https://www.w3.org/TR/rdf-sparql-query/⟩](https://www.w3.org/TR/rdf-sparql-query/).
- [25] *PGQL | Property Graph Query Language*. 2024. Dostupný také z: [⟨https://pgql-lang.org/⟩](https://pgql-lang.org/).
- [26] *GSQL: Graph Query Language*. 2024. Dostupný také z: [⟨https://www.tigergraph.com/gsql/⟩](https://www.tigergraph.com/gsql/).
- [27] Foundation, The GraphQL. *GraphQL: A query language for APIs*. 2024. Dostupný také z: [⟨https://graphql.org/⟩](https://graphql.org/).
- [28] Lawrence, Kelvin R. *Practical gremlin: An apache tinkerpops tutorial*. 2024. Dostupný také z: [⟨https://kelvinlawrence.net/book/PracticalGremlin.html⟩](https://kelvinlawrence.net/book/PracticalGremlin.html).
- [29] *TinkerPop Documentation*. 2024. Dostupný také z: [⟨https://tinkerpop.apache.org/docs⟩](https://tinkerpop.apache.org/docs).
- [30] Bechberger, Dave; Perryman, Josh. *Graph databases in action: Examples in Gremlin*. 1st Edition. 2020. ISBN 978-1-61729-637-6.
- [31] Broecheler, Matthias; Gosnell, Denise Koessler. *Practitioner's Guide to graph data: Applying graph thinking and graph technologies to solve complex problems*. 1st Edition. 2020. ISBN 978-1-492-04407-9.
- [32] Macrometa. *Macrometa*. 2024. Dostupný také z: [⟨https://www.macrometa.com/docs/graphs/graph-concepts/graphs-and-indexes⟩](https://www.macrometa.com/docs/graphs/graph-concepts/graphs-and-indexes).
- [33] Infrabel. *Geographical layout of the distances between two adjacent stations on the rail network*. 2024. Dostupný také z: [⟨https://opendata.infrabel.be/explore/dataset/station_to_station/information/?disjunctive.stationfrom_name&disjunctive.stationto_name&sort=stationfrom_name&basemap=jawg.light&location=8,50.51448,4.32709⟩](https://opendata.infrabel.be/explore/dataset/station_to_station/information/?disjunctive.stationfrom_name&disjunctive.stationto_name&sort=stationfrom_name&basemap=jawg.light&location=8,50.51448,4.32709).
- [34] Needham, Mark; Hodler, Amy E. *Graph Algorithms: Practical Examples in Apache Spark and Neo4j*. 1st Edition. 2019. ISBN 978-1-492-05781-9.

- [35] 2024. Dostupný také z: https://diana.ms.mff.cuni.cz/pogamut_files/lectures/2015-2016/04.2-Pathfinding-Bajer060410.pdf.
- [36] Leskovec, Jure; Krevl, Andrej. *SNAP Datasets: Stanford Large Network Dataset Collection*. 2024. Dostupný také z: <https://snap.stanford.edu/data/com-Youtube.html>.
- [37] Macak, Martin; Stovcik, Matus; Buhnova, Barbora; Merjavy, Michal. How well a multi-model database performs against its single-model variants: Benchmarking OrientDB with Neo4j and MongoDB. In. *Annals of Computer Science and Information Systems*. 2020. FedCSIS 2020. Dostupný také z: <http://dx.doi.org/10.15439/2020F76>.
- [38] Kolomičenko, Vojtěch; Svoboda, Martin; Mlýnková, Irena Holubová. Experimental comparison of graph databases. 2013. Dostupný také z: <http://dx.doi.org/10.1145/2539150.2539155>.